

Traducción del mail al castellano

Para leerlo antes de mandarlo. El que está en tus borradores de Gmail va en inglés.

Para Roi Cohen, Konstantin Dobler, Gerard de Melo (HPI / Universidad de Potsdam) y Eden Biran (Universidad de Tel Aviv)

Asunto Un banco de pruebas en modelo chico para el modo de fallo de [IDK], con otra causa

Estimados Roi, Konstantin, Eden y Gerard,

Soy un investigador independiente y llevo adelante un programa de investigación sobre un modelo de lenguaje deliberadamente diminuto, de 863.859 parámetros, entrenado desde cero y con una memoria persistente explícita. El modelo chico es un banco de pruebas, no el destino. Trabajar a este tamaño tiene un motivo. Una campaña pareada completa, con varias semillas y predicciones pre-registradas, cuesta horas en vez de semanas, así que un mecanismo se puede aislar barato y recién después llevarlo a una escala real. El trabajo de ustedes en NeurIPS 2024 es el antecedente más cercano a lo que estoy haciendo, y con lo primero que me encontré fue con el modo de fallo que reportan.

Ustedes señalan que el método falla en los modelos más chicos que probaron, pythia-70m y pythia-160m, y lo atribuyen a la precisión numérica en la inicialización del embedding de [IDK]. Mi banco cae enteramente dentro de ese régimen, así que puse esa explicación a prueba de manera directa en vez de darla por buena.

Corrí siete unidades en tres condiciones pareadas, veintiuna corridas en total, todas partiendo del mismo checkpoint base, con Adam reinicializado en las tres y el mismo presupuesto de 2000 pasos.

1. **token**, que es el diseño de ustedes. El símbolo de abstención es una entrada más del softmax de vocabulario.
2. **escala**, un intento de llevar su explicación a la práctica. El embedding de abstención se renormaliza a la norma media de los tokens de valor, tanto en la matriz de entrada como en la de salida, al empezar la fase.
3. **cabeza**, una salida binaria de abstención separada, por fuera del softmax de vocabulario. Agrega 129 parámetros sobre 863.730, o sea el 0,015 por ciento.

La compuerta quedó fijada de antemano y exige dos cosas a la vez, porque un modelo que se abstiene de todo saca puntaje perfecto en la primera. Sobre las cinco unidades difíciles, **token** pasa 0 de 5, **escala** pasa 0 de 5 y **cabeza** pasa 4 de 5. En abstención falsa, escala promedia 0,2394 contra 0,0929 de cabeza.

Hay tres detalles que me hacen pensar que la condición 2 es un negativo limpio y no una implementación fallida, y son el motivo por el que les escribo.

Primero. La premisa que la motivaba estaba medida sobre la matriz equivocada. El vector de abstención efectivamente era corto, 0,367 contra alrededor de 1,01 de un token de valor, pero eso es el embedding de entrada. El softmax que realmente decide la respuesta usa la matriz de salida, y ahí el vector de abstención ya era entre 1,77 y 2,05 veces más largo que un valor promedio en las cinco unidades difíciles. En el lugar donde se toma la decisión, el vector no era corto en absoluto.

Segundo. La renormalización sobrevivió al entrenamiento. Entra en 1,000 por construcción y cierra en 0,899 del lado de la entrada y 1,131 del lado de la salida. La norma se quedó donde la pusimos y aun así no alcanzó.

Tercero, y esta es la parte más cercana a su hipótesis. La norma anómala sí tiene un origen en la inicialización. El vector de abstención nunca se entrenó durante la fase base y quedó donde lo inicializaron, mientras los vectores de valor se encogían a su alrededor. Así que la explicación por inicialización acierta en decir de dónde sale la asimetría. Lo que mis corridas sugieren es que no es lo que causa el fallo, porque corregirla explícitamente no cambia nada.

Lo que queda, en mi banco, es que dos decisiones de naturaleza distinta compiten por la masa de un mismo softmax. Si existe una respuesta, y cuál es esa respuesta. Eso es una restricción estructural antes que numérica, y explicaría por qué poner un tope de 0,5 a la masa desplazable ayuda sin llegar a eliminar el problema.

Quiero ser claro con los límites, porque son reales. Esta es una tarea sintética, a una escala muy por debajo de la de ustedes, y con un componente de memoria persistente que sus modelos no tienen. El resultado bien puede no transferirse. Esa es exactamente la pregunta que no puedo contestar desde acá. Todo el diseño de este programa consiste en encontrar mecanismos candidatos de manera barata y después replicarlos donde importan, y no tengo forma de hacer la segunda mitad por mi cuenta.

Así que el motivo de este mail es doble. Si el mecanismo realmente es el softmax compartido, una cabeza binaria separada es una intervención del 0,015 por ciento que valdría una sola ablación a la escala de ustedes. Y si les parece que el resultado en modelo chico es un artefacto de mi banco, prefiero escucharlo de ustedes antes que seguir construyendo encima.

Con gusto comparto el código, el pre-registro y las corridas completas, y me ofrezco a ayudar a armar esa ablación si les resulta de interés.

Saludos cordiales,

Maximiliano R. Speranza
Investigador independiente
ORCID 0009-0005-0413-8554

Notas sobre esta traducción

El mail que está en tus borradores de Gmail va **en inglés**. Esto es sólo para que lo puedas leer cómodo antes de decidir.

Todos los números salen de `INFORME_CABEZA_20260819.md` verificado hoy contra el archivo, no de lo que yo recordaba. Esa verificación cambió el mail y lo mejoró. La frase del tercer punto, que la inicialización explica de dónde sale la asimetría pero no explica el fallo, es más precisa y más difícil de rebatir que decir que su hipótesis está equivocada.

El segundo mail, el del endorsement de arXiv, **no** está en borradores a propósito. Va sólo si contestan este, y además necesita un código que arXiv genera recién cuando lo pedís desde tu cuenta. Está guardado en `mail_2_endorsement_arxiv.txt`.