

Micro-LM

Un modelo de lenguaje de 3,5 MB entrenado desde cero, con el archivo de memoria dentro de la red
Informe de construcción · 17 de agosto de 2026 · Maximiliano Speranza, investigador independiente · ORCID 0009-0005-0413-8554

En una frase. El Micro-LM es un modelo de lenguaje minúsculo —863.730 parámetros, 3,5 MB— entrenado **desde cero** con una particularidad: no aprende a escribir textos bonitos, aprende a **no olvidar lo que le dijeron** y a **decir «no sé»** cuando no se lo dijeron. El archivo de memoria no es una base de datos externa pegada por afuera: **está adentro de la red y se entrena junto con ella.**

1 · Qué problema resuelve

Un modelo de lenguaje corriente tiene dos fallas que no se arreglan haciéndolo más grande. La primera: cuando la conversación termina, olvida todo. La segunda: cuando no sabe algo, **lo inventa igual, y con la misma seguridad que cuando sí sabe**. Las dos fallas tienen la misma raíz —el modelo no distingue mecánicamente entre *recordar* e *inventar*— y por eso este proyecto las ataca juntas.

El objetivo, en palabras del autor, es «**que un LLM no olvide nunca lo que le dije**». El énfasis está en *lo que le dije*: no se trata de leer más documentos, sino de recordar lo que una persona concreta le contó, incluso cuando después lo **corrige**. Ésa es la tarea canónica:

```
sesión 1 · usuario: el director de norte es ana
sesión 2 · usuario: no , el director de norte es beto
sesión 5 · usuario: quien dirige norte ?
           modelo: beto
```

Parece trivial y no lo es: el modelo tiene que archivar el hecho, archivar la corrección, entender que la segunda **reemplaza** a la primera, y recuperar la versión vigente varias sesiones después, con la memoria de trabajo reseteada en el medio.

Por qué un modelo tan chico

Porque a esta escala se puede **mirar todo**. Con 863.730 parámetros se puede abrir el modelo, medir qué entrada del archivo ganó la lectura, y saber si un error fue de escritura o de lectura. En un modelo de frontera eso es imposible. El tamaño no es una limitación asumida a regañadientes: es el instrumento.

2 · El idioma cerrado

El lenguaje acá es la **interfaz** de la prueba, no el objeto de estudio. Por eso el vocabulario es cerrado y minúsculo: **242 tokens en total**.

Grupo	Tokens	Contenido
Números	100	0 ... 99 — los valores no personales
Nombres	58	ana beto carla dario...
Entidades	29	norte sur taller museo puerto...
Funcionales	35	el la de es no ahora quien...

Control	9	BOS SEP EOS USUARIO MODELO NOSE ? , .
Relaciones	6+	director, precio, altura, dueño, guardia, clave

La respuesta es siempre un solo token —un valor, o el token NOSE—. Esa decisión de diseño hace que la métrica sea exacta: no hace falta un juez ni un parser que interprete texto libre. Se aprendió a los golpes: el 12 de agosto, 10 de 11 «abstenciones» resultaron ser el modelo contestando bien otra cosa y el parser anotándolo mal.

Los cuatro niveles de dificultad

Nivel	Qué agrega	Por qué es más difícil
N1 plantilla fija	una sola forma de decir cada hecho	basta con memorizar la forma
N2 paráfrasis	cuatro formas del mismo hecho	el salto real: obliga a indexar por contenido, no por forma
N3 corrección elíptica	no , es beto — sin nombrar la entidad	hay que saber de qué se está hablando
N4 multi-sesión	varias sesiones, preguntas al final	la memoria de trabajo se resetea entre sesiones

Un episodio real generado por el sistema, nivel 4:

sesión 1: dario cuida faro | no , es ciro | barrio vale 79 | mercado cuesta 99

sesión 2: no , la clave de barrio es 33

sesión 3: (vacía)

preguntas

cual es el guardia de faro ? → ciro (no dario: hubo corrección elíptica)

cual es la clave de barrio ? → 33 (no 79: corregido en otra sesión)

cual es el precio de mercado ? → 99

3 · Qué es una red neuronal acá, en concreto

Antes del plano general, lo elemental: **una capa de una red neuronal es una tabla de números (pesos) que mezcla una lista de números de entrada para producir otra de salida.** Cada círculo del dibujo es una *neurona* —un número—, y cada línea es un *peso* —cuánto influye esa entrada en esa salida—. Entrenar es ajustar los pesos.




Figura 1 — Una capa densa. En el Micro-LM cada vector tiene **128 números** (no 4), y hay muchas capas de éstas encadenadas. El principio es el mismo.

4 · La arquitectura completa

Éste es el plano general. La diferencia con un transformer común está en las **dos ramas**: la conversación pasada se **archiva** (izquierda) y la pregunta actual **lee ese archivo** (derecha) mientras se procesa.




Figura 2 — Arquitectura completa. Las dos ramas comparten el mismo tronco de 4 bloques: los mismos pesos leen y escriben, y por eso el archivo se entrena junto con el modelo.

5 · Un bloque por dentro

Cada uno de los 4 bloques del tronco tiene tres piezas en serie. Todas suman su resultado a la señal que viene (las «conexiones residuales», las flechas que rodean cada caja): así la información original nunca se pierde.



Figura 3 — Un bloque. Las líneas punteadas son las conexiones residuales.

6 · Las cuentas del modelo

Pieza	Valor	Entrenamiento	Valor
Vocabulario (V)	242	Pasos	12.000
Ancho del vector (D)	128	Lote	64 episodios
Bloques	4	Tasa de aprendizaje	1e-3
MLP interno	512	Programa	warmup + coseno
Sellos de orden	64	Preguntas por versión vieja	35 %
Parámetros totales	863.730	Tiempo en GPU T4	~1 h
Tamaño (fp32)	3,5 MB	Tiempo en esta PC	~27 h
Checkpoint completo	9,9 MB	Optimizador	AdamW (optax)

Un detalle que importa: el 35 % de las preguntas son por la versión *anterior* del hecho, no por la vigente. Sin eso, el modelo aprendería el atajo de «*contestá siempre lo último que escuchaste*» y nunca aprendería a manejar versiones.

7 · Cómo se mide, y por qué así

Cada métrica existe para cerrarle la puerta a una forma de hacer trampa. Un instrumento que no puede fallar no mide nada.

Métrica	Qué mide	Qué trampa impide
vigente	acierto en la versión que rige hoy	—
anterior	acierto en la versión vieja	contestar siempre lo último dicho
nose	se abstiene cuando NO hay respuesta	inventar
falsa_abst	se abstiene cuando SÍ había respuesta	abstenerse de todo
nose_ent / nose_rel	los dos tipos de ausencia, separados	que uno fácil tape al difícil

La compuerta de abstención: $\text{nose} \geq 0,50$ Y $\text{falsa_abst} \leq 0,10$. Las dos juntas, y no una sola. Un modelo que dijera NOSE a absolutamente todo sacaría $\text{nose} = 1,0000$ —perfecto— y sería completamente inútil. Lo delata $\text{falsa_abst} = 1,0000$. El instrumento se verificó contra cuatro modelos simulados (oráculo, el que nunca se abstiene, el que siempre se abstiene, y el azar): **pasó las 10 comprobaciones**, incluida la de rechazar a los dos degenerados.

8 · Resultados al 17 de agosto

Memoria: resuelta en el régimen medido

La campaña base entrena el modelo sin preguntas sin respuesta, para medir sólo la memoria. **11 de 12 corridas cerradas** (la última en curso). Los niveles 1 y 2 llegan a **1,0000**; el nivel 4 —multi-sesión, con correcciones elípticas— se estabiliza en **0,75-0,77**. Un modelo de 3,5 MB recuerda qué le dijeron, qué corrigieron y en qué orden, varias sesiones después.

Abstención: el hallazgo del día

La pregunta era si el mismo modelo puede aprender a decir «no sé». La estrategia probada hoy es un **currículum**: entrenar primero sin preguntas sin respuesta hasta que el modelo domine la tarea, y recién entonces introducirlas. El resultado se parte exactamente en dos.




Figura 4 — Cada punto es un modelo entrenado. Verde = pasa la compuerta, rojo = falla. La separación es total, pero **la frontera no está medida**: no hay ningún punto entre +0,24 y +0,41.

Modelo	margen	vigente	nose	falsa_abst	compuerta
x1_s0 · nivel 1	+0,4094	0,9890	0,8844	0,0095	PASA
x2_s2 · nivel 2	+0,4071	0,9851	0,9762	0,0163	PASA
x3_s2 · nivel 3	+0,2358	0,5656	0,6379	0,2237	falla
x3_s1 · nivel 3	+0,1870	0,6388	0,5765	0,1757	falla
x4_s1 · nivel 4	+0,1787	0,7004	0,6891	0,1599	falla
x4_s0 · nivel 4	+0,1672	0,7047	0,7106	0,1342	falla

Lo que sí se puede afirmar. En los dos casos donde el modelo dominaba la tarea con holgura antes de introducir «no sé», **aprendió a abstenerse casi perfecto sin volverse tímido**: detecta entre el 88 % y el 98 % de las preguntas sin respuesta, equivocándose en menos del 2 % de las que sí la tenían. Y ninguno de los seis fracasa por *no detectar* la ausencia: la métrica nose está entre 0,58 y 0,98 en todos. **Lo que falla siempre es lo mismo: se callan de más.**

Lo que NO se puede afirmar todavía. Son seis modelos, sin réplica en la mayoría de las celdas, y con la frontera sin muestrear. Además falta el **control que puede tumbar todo**: entrenar asignando «no sé» al azar al 40 % de las preguntas, tengan respuesta o no. Ese control hereda la frecuencia sin la señal; si el modelo entrenado no le gana claramente, lo que aprendió es a decir «no sé» seguido, no a saber cuándo. Está pre-registrado para mañana.

9 · Lo que este trabajo NO afirma

Conviene decirlo con todas las letras, porque es donde este proyecto se separa del discurso habitual: **«eliminar las alucinaciones» no es afirmable con este instrumento**, y una revisión externa nos obligó a corregir un informe interno que lo insinuaba.

La abstención no elimina el error: lo convierte de **silencioso** en **avisado**, y compra una posición en la curva riesgo-cobertura. Además, «cero errores observados» nunca significa «eliminado»: con n preguntas y

cero fallos, la cota superior al 95 % es $\approx 3/n$ —para sostener «inventa menos del 0,1 %» harían falta unas 3.000 preguntas sin un solo fallo.

Y hay tres clases de alucinación con tres destinos distintos:

Clase	Qué es	Destino
1 · Invento	no hay respuesta y contesta igual	eliminable — la ausencia deja firma
2 · Confusión al leer	dos entradas del archivo compiten	convertible en abstención
3 · Memoria falsa	la corrección se ligó al hecho equivocado al escribir	indetectable por abstención, por diseño

La clase 3 es la más incómoda: al leerla, el hecho falso tiene puntaje alto y baja incertidumbre —es **mecánicamente idéntico** a uno verdadero—. Ninguna cantidad de abstención la va a tocar. Ahí hay que intervenir en la escritura, no en la lectura.

10 · Qué sigue

Próximo paso	Por qué
Cabeza de abstención separada	Hoy «NOSE» es un token más y compite en el mismo softmax que los 241 valores. Eso mezcla dos decisiones muy distintas: una binaria y balanceada («¿está?») contra una de 1-entre-100 («¿qué valor?»). Esa asimetría explica por qué el modelo se calla de más. Separarlas es el cambio de fondo.
Control de permutación	El único control que puede invalidar el resultado positivo. 45 minutos.
Muestrear la frontera	Ningún punto entre margen +0,24 y +0,41. Ahí está la respuesta a «¿cuánto hay que saber antes de poder aprender a dudar?»
Arreglar el ranking de lectura	Ya está medido que el hecho siempre está escrito : lo que se pierde es el puesto en el ranking al leer. El arreglo va en la lectura, no en la escritura.
Nombres nunca vistos	Entrenar con 40 de los 60 nombres y evaluar con los 20 restantes convierte «memorizó pares» en sistematicidad . Barato.

La pregunta grande, que sale de cruzar las dos líneas del proyecto. Está medido que el contexto sirve sólo si llega **antes** del cómputo: un mismo acceso vale 0,9998 en el primer bloque y 0,4990 en el último. Si eso vale también para un archivo persistente, entonces lo que se recupera de la memoria **no puede inyectarse al final** — que es exactamente lo que hace todo sistema RAG hoy. Este modelo inyecta en el bloque 0 justamente por eso.