

Un modelo de lenguaje que sabe decir «no sé»

Informe de resultados — 18 de agosto de 2026

Maximiliano Speranza — investigador independiente

ORCID 0009-0005-0413-8554

Para quién es este documento. Está escrito para que se entienda sin saber nada de inteligencia artificial. Cada término técnico se explica la primera vez que aparece. Los números que figuran acá son los que ya están medidos y verificados; al final hay una sección con lo que todavía *no* sabemos, que es igual de importante.

1. El problema, en una página

Cuando un sistema de inteligencia artificial no sabe algo, casi nunca lo dice. Inventa una respuesta con el mismo tono seguro que usa cuando acierta. A eso se le llama **alucinación**.

El daño no es la respuesta equivocada en sí. Es lo que esa respuesta le hace a todas las demás:

Un error silencioso no cuesta una respuesta. Cuesta **la confianza en todas las otras**. Si el sistema inventa una de cada diez veces y nunca avisa cuál, hay que verificar las diez.

Este trabajo ataca tres cosas que en realidad son la misma:

1. Que el modelo **no olvide** lo que se le dijo antes.
2. Que **sepa decir «no sé»** cuando no lo tiene.
3. Que **no invente** cuando no sabe.

Son la misma porque un modelo que recuerda bien, pero no distingue entre «me acuerdo» y «no me acuerdo», va a inventar exactamente en los casos en que olvidó.

2. Qué se construyó

Un modelo de lenguaje entrenado **desde cero**, deliberadamente diminuto:

Tamaño	863.730 parámetros — 3,5 MB
Vocabulario	242 palabras
Idioma	artificial, cerrado, pero legible
Entrenamiento	desde cero, sin partir de ningún modelo existente

Para comparar: los modelos comerciales tienen entre cien mil y un millón de veces más parámetros. Un **parámetro** es un número que el modelo ajusta mientras aprende; son las perillas internas que definen su comportamiento.

¿Por qué tan chico a propósito? Porque acá no se busca que sepa mucho, sino poder *ver* qué hace por dentro. En un modelo gigante, averiguar por qué inventó algo es prácticamente imposible: hay demasiadas piezas. En uno de 3,5 MB se puede abrir, medir cada parte y hacer experimentos controlados en horas en vez de meses.

La diferencia con lo que se hace habitualmente

La forma normal de que un sistema «recuerde» es pegarle un buscador por afuera: cuando llega una pregunta, el buscador va a una base de datos, trae textos parecidos y se los pasa al modelo. El modelo, en sí mismo, no recuerda nada.

Acá el archivo de memoria está **adentro de la arquitectura**, y se entrena junto con el resto. El modelo no recibe textos: escribe sus propios recuerdos y aprende a consultarlos. Eso le permite contestar sobre algo dicho en una conversación anterior **cuyo estado interno ya se borró**, y si el dato se corrigió después, contestar con la versión corregida.

3. Los cinco resultados que ya están asegurados

1. El modelo nunca olvida escribir: se equivoca al leer

Cuando el modelo se equivoca de dato, ¿es porque no lo guardó, o porque no lo encontró?

Se revisaron 8000 casos. **El dato buscado estaba guardado en el archivo en el 100 % de ellos** — literalmente ni un caso de 8000 en que faltara.

Cuando responde mal, el dato correcto está ahí, en el segundo puesto de su propia lista de candidatos, y sólo gana entre el 14 y el 18 % de las veces. Cuando responde bien, está en el primer puesto.

Por qué esto es una buena noticia: un error de escritura sería irreparable — lo que no se guardó no se puede recuperar. Un error de *lectura* es distinto: la información está, sólo falta reconocer que la búsqueda salió mal. **Y eso se puede convertir en un «no sé».**

2. Cuando dice «no sé», es porque fue a buscar y no encontró

Un modelo podría aprender a decir «no sé» por el motivo equivocado: reconociendo la *forma* de la pregunta en lugar de consultar su memoria. Sería un truco, no memoria.

El control: se toma la misma pregunta, en el mismo contexto, y se cambia una sola cosa — si el dato está guardado o no.

Situación	Veces que dice «no sé»
El dato no está en su memoria	≈ 90 %
El dato sí está	0,6 % a 2,2 %

Con el dato disponible deja de abstenerse y responde, acertando el valor correcto entre el 98 y el 99 % de las veces. **Está consultando su memoria de verdad.**

3. El hallazgo principal: la abstención necesita su propia salida

Acá está el resultado central, y es de *arquitectura* — de cómo está construido el modelo, no de cuánto se lo entrena.

Originalmente, «no sé» era una palabra más del vocabulario. Para responder, el modelo elegía entre todas sus palabras: «ana», «beto», «743»... y «no sé». Todas competían en la misma votación interna.

El problema es que ahí se mezclan dos preguntas de naturaleza distinta:

- «¿Tengo el dato?» — una pregunta de sí o no, más o menos balanceada.

- «¿Cuál es el valor?» — una elección entre cien opciones.

La propuesta fue **separarlas**: darle a la abstención una salida propia, independiente de la votación por el valor. Cuesta 129 parámetros más sobre 863.730 — un 0,015 %.

Se probaron tres versiones sobre los mismos modelos, con el mismo entrenamiento y el mismo presupuesto, cambiando *únicamente* dónde se toma la decisión de callarse:

Versión	Modelos que pasan la prueba	Error medio
Salida propia	4 de 5	0,093
Palabra más del vocabulario	0 de 5	0,186
Palabra, pero «amplificada»	0 de 5	0,239

De 0 de 5 a 4 de 5 cambiando dónde se decide, no cuánto se entrena.

El «error medio» de la tabla es la **falsa abstención**: cuántas veces dice «no sé» aunque sí tenía el dato. Es el precio de enseñarle a callarse, y es el que hay que mantener bajo — porque un modelo que contesta «no sé» a todo nunca se equivoca, y tampoco sirve para nada.

4. No era el tamaño: era la competencia

La tercera versión de la tabla merece una explicación, porque su fracaso enseña algo.

Se había observado que el vector interno de «no sé» era tres veces más corto que el de una palabra normal — como si compitiera en desventaja. La versión «amplificada» lo agrandaba para emparejarlo.

Fracasó en los cinco modelos, y peor que no hacer nada. Al ir a mirar por qué, apareció que la observación original mezclaba dos partes distintas del modelo: en la parte que *de verdad* decide la respuesta, «no sé» no estaba en desventaja — era casi el **doble** de largo que una palabra normal.

Conclusión: el problema nunca fue el tamaño del vector. Era que dos decisiones distintas compartían la misma votación. Emparejar los tamaños no cambia nada; separar las decisiones sí.

5. Lo que falta es calibración, no capacidad

De los cinco modelos, uno no llegó a pasar la prueba. ¿Le falta capacidad, o sólo está mal ajustado?

El modelo produce internamente un número que indica «cuán seguro estoy de que no lo tengo», y después lo compara con un punto de corte para decidir si se calla. Ese punto de corte estaba fijado en el valor de manual, sin ajustar.

Midiendo qué tan bien ese número separa los casos en que el dato está de los casos en que no está, la puntuación va de **0,77 a 0,99** (donde 0,5 sería no distinguir nada y 1,0 sería perfecto). **La señal está y es buena.** Ajustando el punto de corte con datos separados de los de la evaluación, pasan 5 de 6 modelos — incluido el que fallaba.

4. Cómo sabemos que esto es cierto

Todo se predice por escrito antes de medir

Cada experimento se escribe primero: qué se espera, con qué números exactos se considera confirmado y con cuáles refutado. Ese documento se sella con una **huella digital criptográfica** — un código que cambia si se altera una sola letra — y se publica con fecha antes de correr nada.

Sirve para una cosa concreta: hace imposible acomodar el criterio después de ver los resultados. Es una práctica común en medicina y rara en inteligencia artificial.

Se reportan también los resultados incómodos

En este mismo informe hay dos ejemplos:

- Una de las cuatro predicciones **no se cumplió** en su forma literal. El desvío fue *a favor* del resultado — el modelo con salida propia recuerda mejor de lo permitido por el criterio — pero queda registrado como incumplimiento, sin cambiar el criterio después.
- La primera versión de un análisis dio un resultado demasiado bueno porque el ajuste y la medición usaban los mismos datos. Se rehizo separándolos y el resultado bajó.

A lo largo del proyecto se detectaron **ocho** casos en que un número limpio escondía un error de instrumentación. Todos están documentados. La costumbre de buscarlos es parte del método.

5. Lo que todavía no sabemos

- **Es un idioma artificial de 242 palabras**, no lenguaje humano. Que el mecanismo funcione acá no garantiza que funcione a escala real: lo hace plausible y medible.
- **Un modelo de cinco no pasa** con el ajuste de fábrica. Hay evidencia de que es calibración, pero se midió después de ver los resultados, así que es una pista fuerte, no una conclusión.
- **No sabemos cuán entrenado tiene que estar** el modelo antes de poder enseñarle a callarse. Si hiciera falta entrenarlo casi hasta la perfección, el método no serviría en la práctica. Ese experimento está corriendo mientras se escribe este informe.
- **El ajuste del punto de corte no está probado** como parte de un experimento predicho de antemano. Requiere su propio registro previo.

6. Por qué importa

Hoy la industria intenta que los modelos no inventen **pidiéndoselo**: instrucciones, filtros, verificadores externos. Todo por afuera del modelo.

Lo que estos resultados sugieren es distinto: **callarse a tiempo puede ser una propiedad de cómo está construido el modelo**. No hace falta que sea más grande ni que se lo entrene más. Hace falta que la decisión de «no sé» no compita con la decisión de «qué respondo».

Ciento veintinueve parámetros sobre ochocientos sesenta mil. Un 0,015% más de modelo, y pasa de no poder callarse nunca a poder hacerlo casi siempre.

Todos los experimentos citados están registrados con huella criptográfica y fecha anterior a su ejecución.

Documento generado el 18 de agosto de 2026.