

La abstención perfecta es conocimiento nulo

Dos puntos fijos estables de un objetivo de abstención autorreferencial en un modelo de lenguaje chico con memoria versionada

Maximiliano Speranza
Investigador independiente, Buenos Aires, Argentina
[ORCID 0009-0005-0413-8554](https://orcid.org/0009-0005-0413-8554)
mrsperanza@frba.utn.edu.ar

Septiembre de 2026

Resumen

Un detector de alucinaciones tendría que predecir los errores de su propio modelo, así que el blanco natural de entrenamiento es autorreferencial. Cada ejemplo se etiqueta según si el modelo *se equivocaría en caso de contestar*. Entrenamos ese blanco en un modelo de lenguaje de 863,730 parámetros con un archivo versionado co-entrenado, dejando fijas la arquitectura, los datos y el presupuesto, y encontramos que el objetivo tiene **dos puntos fijos estables**. Nueve unidades se reparten 5 y 4 entre ellos, y el reparto lo gobierna **cuánta recuperación tenía ya el modelo cuando empezó el entrenamiento de abstención**. Seis unidades que arrancaron de cero se reparten 2 y 4, mientras que tres que heredaron 12,000 pasos de pre-entrenamiento de recuperación (RECUP 0,77 a 0,80) alcanzaron el punto útil 3 de 3.

El degenerado es el hallazgo. Cuatro de nueve unidades convergen a un estado que puntúa **nose** = 1,0000 y **invento** = 0,0000, *perfecto* en las dos métricas que la literatura de abstención informa, mientras su exactitud global queda en 0,4065, que es exactamente el piso trivial que se obtiene abstiéndose en todo. No son detectores que fallan. Son **detectores perfectamente calibrados de un generador que no sabe nada**, y la calibración es honesta, porque el modelo no recupera y lo informa correctamente. Su cabeza binaria colapsó a una constante con AUC de 0,522 a 0,578 sobre su propio blanco, y esa constante se ubica donde la predice el prior. Para la unidad más joven, el logit de la tasa de error base vale 1,513 contra una mediana medida de 1,507.

La bifurcación se decide temprano y es nítidamente legible. En el paso 2500, sobre el lote de evaluación de 512 muestras que el propio bucle de entrenamiento ya computa, las cinco unidades sobrevivientes habían emitido 2, 4, 4, 8 y 1 respuestas, y las cuatro degeneradas habían emitido **cero**. La regla “cero contra no cero en el paso 2500” separa **40 de 40** corridas con cabeza binaria en doce familias de este repositorio, y una unidad sobrevivió con una *sola* muestra de 512. La fase muda inicial pertenece al blanco autorreferencial. Sobre el control pareado que comparte semilla *y* inicialización, tres unidades con un blanco fijo e independiente del modelo leen entre 0,06 y 0,20 contra 0,98 y 0,99 de sus gemelas autorreferenciales.

El punto degenerado es **absorbente** y no meramente lento. Medir la recuperación dentro de una misma unidad con muestras pareadas a lo largo de 4000 pasos más da $-0,0021$, o sea $0,4\sigma$, y no se mueve. Informamos además una corrección a nuestra propia primera lectura, en la que una tendencia entre unidades que sobrevive a un control de ruido ($r = 0,986$) igual no era extrapolable, porque la curva es cóncava y un ajuste lineal escondía una saturación.

La consecuencia práctica es una afirmación sobre métricas y no sobre arquitectura. **Cualquier criterio de éxito que lea tasa de abstención y tasa de fabricación sin leer exactitud global queda maximizado por un modelo que no aprendió nada**, y un objetivo autorreferencial aporta una dinámica de entrenamiento que alcanza ese máximo por sí sola, en una fracción sustancial de las corridas, sin aviso de ninguna de las dos métricas.

Palabras clave. abstención; detección de alucinaciones; predicción selectiva; objetivos autorreferenciales; dinámica de entrenamiento; soluciones degeneradas; modelos de lenguaje chicos; memoria persistente

1. La métrica que gana un modelo callado

La literatura sobre abstención informa dos números. Uno es la tasa con la que un modelo se niega correctamente a contestar preguntas que no puede contestar, y el otro es la tasa con la que fabrica. Los dos son deseables, los dos están acotados, y un sistema que mejora en ambos se toma normalmente como un sistema que mejoró.

Un modelo que se abstiene en todas las preguntas puntúa perfecto en los dos.

No es una observación sutil, y como punto abstracto tampoco es nueva. La literatura de predicción selectiva siempre emparejó riesgo con cobertura, precisamente porque el riesgo solo se minimiza de forma trivial (El-Yaniv and Wiener, 2010; Geifman and El-Yaniv, 2017). Lo que informamos acá es que la esquina degenerada no solo es alcanzable en principio sino que es un **atractor de un objetivo de entrenamiento natural**, que una fracción sustancial de las corridas cae en ella, y que una vez adentro el estado es estable si se sigue entrenando.

El objetivo en cuestión es el que un detector de alucinaciones realmente quiere. Un detector sirve si predice los errores *de este modelo*, así que el blanco no debería ser “¿existe la respuesta?” sino “¿me voy a equivocar si contesto?”. Ese blanco está disponible gratis durante el entrenamiento. Se toma el propio **argmax** del modelo, se compara contra la etiqueta y se usa la comparación como blanco binario con el gradiente cortado. Es lo natural, y en este banco es lo que produjo las unidades de las que trata este trabajo.

Su defecto es estructural antes que incidental. La etiqueta es función del propio estado del modelo, así que se mueve mientras el modelo aprende, y el mapa tiene más de una solución consistente. En la inicialización el modelo se equivoca en casi todo, con lo cual el blanco es la constante 1 y la cabeza aprende a predecir “me voy a equivocar”, que es *cierto*. Escapar exige que el generador empiece a acertar antes de que la cabeza termine de asentarse en la constante. Es una carrera entre dos escalas de tiempo de aprendizaje, y la sección 5.1 muestra que tanto la semilla como la cantidad de recuperación que el modelo ya tiene cuando arranca la carrera deciden cuál gana.

Los dos desenlaces son autoconsistentes, y eso es lo que vuelve estable al degenerado.

punto fijo	qué afirma el modelo, y si es cierto
útil	“recupero bien, y sé cuándo voy a fallar”, y es cierto
degenerado	“no recupero casi nada, y sé que no recupero casi nada”, y también es cierto

El modelo degenerado no está mal calibrado. Es honesto, inútil e invisible para las dos métricas que el campo informa.

Contribuciones.

1. Caracterizamos el punto fijo degenerado de un objetivo de abstención autorreferencial y mostramos que lo alcanzan 4 de las 6 unidades entrenadas desde cero, y ninguna de las 3 que heredaron pre-entrenamiento de recuperación (sección 5.1).
2. Mostramos que las unidades degeneradas *no* son detectores rotos. Sus cabezas colapsaron al prior, y lo verificamos cuantitativamente contra la constante en forma cerrada, no solo de manera cualitativa (sección 5.2).
3. Mostramos que la bifurcación queda decidida para el paso 2500 y es separable con una regla de cero contra no cero sobre datos que el bucle de entrenamiento ya produce, validada en 40 corridas (sección 5.3).
4. Mostramos que el punto degenerado es absorbente y no lento, usando la primera medición dentro de una misma unidad que se hace en esta línea de trabajo (sección 5.5).

5. Corregimos una primera lectura de nuestros propios datos, en la que una tendencia real entre unidades se extrapoló con la forma funcional equivocada (sección 5.6).

2. Trabajo relacionado

Predicción selectiva. El marco de riesgo y cobertura (El-Yaniv and Wiener, 2010; Geifman and El-Yaniv, 2017) existe porque la abstención se cambia contra la utilidad, y SelectiveNet (Geifman and El-Yaniv, 2019) vuelve explícito ese intercambio entrenando una cabeza de selección contra una restricción de cobertura. Nuestras unidades degeneradas son la razón de ser de esa restricción, observada como desenlace de entrenamiento y no como argumento.

Aprender a decir “no sé”. Agregar un token [IDK] al vocabulario (Cohen et al., 2024) y agregar una cabeza binaria separada son las dos interfaces dominantes. Comparamos cuatro de ellas con presupuesto igualado en un trabajo previo (Speranza, 2026) y encontramos que la cabeza es superior en este régimen. Esa comparación usaba un blanco *fijo*, “¿existe la respuesta?”, y ninguna de sus unidades entró en el estado que se describe acá. El presente trabajo es lo que pasa cuando el blanco se vuelve autorreferencial.

Blancos autorreferenciales y bootstrapeados. Entrenar un predictor contra etiquetas derivadas del modelo actual es estándar en autoentrenamiento y pseudo-etiquetado, y el modo de falla por sesgo de confirmación está bien documentado (Arazo et al., 2020). Nuestro aporte no es que los blancos autorreferenciales puedan colapsar, cosa esperable, sino la forma específica del colapso en el contexto de la abstención. El estado colapsado es *correcto*, puntúa perfecto en las métricas estándar y por lo tanto esas métricas no lo detectan como falla.

Soluciones degeneradas y colapso. Los métodos de aprendizaje de representaciones que predicen sus propias salidas colapsan a constantes si no se les pone un remedio explícito (Grill et al., 2020; Chen and He, 2021). El mecanismo acá es de la misma familia, un blanco que el modelo puede satisfacer moviendo el blanco, pero la solución colapsada no es una representación constante sino una *decisión* constante, y esa constancia es exactamente lo que la hace puntuar bien.

3. El banco

El banco es el que describe Speranza (2026). Repetimos acá lo necesario para leer los resultados y remitimos ahí para el resto.

Modelo. Un modelo de lenguaje entrenado *desde cero*, sin ningún componente pre-entrenado. Son 863,730 parámetros, 3,5 MB y un vocabulario cerrado de 242 tokens legibles por humanos. Una recurrencia de regla delta más un **archivo persistente co-entrenado** con un sello de orden aprendido en la clave, leído por softmax e inyectado en el bloque 0. El archivo persiste entre sesiones mientras que el estado recurrente se reinicia entre ellas.

Tarea. Los hechos se enuncian en una sesión, se corrigen en otra y se consultan en una tercera. La respuesta es un **token único**, así que la métrica es exacta y determinista, sin juez LLM y sin parser interpretativo. El 40 % de las preguntas no tiene respuesta ($p_{\text{nose}} = 0,4$), y la fracción empírica en la muestra de evaluación es 0,4065.

Interfaz. Todas las unidades de este trabajo usan la cabeza binaria separada, que fue la que seleccionó la comparación previa. Es un escalar a proyectado desde el mismo estado final que alimenta el softmax de vocabulario, con +129 parámetros. El modelo se abstiene cuando $a > 0$. Informar el colapso sobre la interfaz *ganadora* es deliberado, porque así no queda como artefacto de un mecanismo de abstención débil.

Métricas. *vigente* es la exactitud sobre el valor actual *tal como se emite*, o sea después de la decisión de la cabeza. *nose* es la tasa de abstención en preguntas sin respuesta. *falsa_abst* es la tasa de abstención en preguntas que sí la tienen. *invento* es la tasa de respuestas que nombran contenido ausente del archivo. Agregamos dos instrumentos.

- **Exactitud global**, definida como (respuestas correctas más abstenciones correctas) sobre n . Su piso trivial en este banco es **0,4065**, que se obtiene abstiéndose en todo.
- **RECUP**, la exactitud de recuperación *ignorando la cabeza*, o sea el **argmax** sobre valores en las preguntas que sí tienen respuesta, sin aplicar la decisión de abstención. *vigente* es un compuesto de recuperación y decisión, y vale 0,0000 siempre que $a > 0$ en todas partes, sin importar qué recuperó el modelo. RECUP separa las dos cosas.

Protocolo de medición. RECUP se mide con $n = 8000$ y una semilla de datos fija (54321) en todos los checkpoints, de modo que las comparaciones son **pareadas**. Las preguntas son idénticas y lo único que cambia es el modelo. Esto importa. Medida sobre seis semillas de datos con $n = 2000$, RECUP tiene $\sigma = 0,0135$, así que una diferencia no pareada arrastra $\sigma \approx 0,0191$, que es más grande que los efectos de interés. Informamos p_{flip} , la fracción de preguntas en las que dos checkpoints difieren, y de ahí derivamos el desvío estándar pareado en vez de suponer un valor.

Protocolo. Cada campaña tiene un preregistro congelado con su SHA antes de la implementación, un archivo de desvíos y reporte por unidad. **Los resultados nunca se informan como un promedio solo.** La bimodalidad entre semillas es una propiedad medida de este banco, y la sección 5.1 es una consecuencia directa de eso.

Uso de un modelo de lenguaje. Todo el código de experimentación, las campañas de entrenamiento y la generación de informes de este trabajo se hicieron con la asistencia de un modelo de lenguaje grande. El diseño del estudio, los preregistros y sus hashes congelados, la elección de los controles y la verificación de cada número informado son del autor. El modelo no es autor y no tiene responsabilidad sobre el trabajo.

4. El objetivo

Escribimos ℓ para los logits de valor, y para la etiqueta y a para el escalar de la cabeza. El blanco autorreferencial es

$$b = \mathbb{I}[\text{sg}(\arg \max_{v \neq \text{NOSE}} \ell_v) \neq y], \quad \mathcal{L} = \text{BCE}(a, b) + \text{CE}_{\text{valor}},$$

con sg el corte de gradiente. En las preguntas sin respuesta, $b = 1$ por construcción. La entropía cruzada de valor se computa solo donde existe respuesta y se normaliza por esa fracción, de modo que la escala de la pérdida no dependa de p_{nose} .

De ahí se siguen dos propiedades directas que conviene enunciar antes de cualquier medición, porque son las que los resultados confirman.

El gradiente de valor nunca queda condicionado por la cabeza. CE_{valor} no depende de a . Le pase lo que le pase a la cabeza, la recuperación sigue recibiendo gradiente. El colapso que informamos más abajo no es entonces un caso de “el modelo deja de aprender porque dejó de contestar”, una hipótesis que sostuvimos y refutamos (sección 5.1).

Si la cabeza ignora su entrada, su óptimo es el prior. Una constante a que minimiza la BCE contra b vale $\logit \mathbb{E}[b]$, y $\mathbb{E}[b]$ se computa en forma cerrada a partir de RECUP.

$$\mathbb{E}[b] = p_{\text{nose}} + (1 - p_{\text{nose}})(1 - \text{RECUP}), \quad p_{\text{nose}} = 0,4065. \quad (1)$$

Es una predicción sin ningún parámetro libre, y la sección 5.2 la pone a prueba.

5. Resultados

Nueve unidades, semillas 0 a 8, con banderas idénticas. Cinco llegan a un estado útil y cuatro no. Informamos por unidad en todo el trabajo.

Un confundido en el punto de partida, encontrado tarde e informado completo. Las nueve unidades *no* son homogéneas, y nos dimos cuenta después de escrito el análisis que sigue. El arnés de entrenamiento siembra la fase de abstención desde un checkpoint base cuando existe uno para esa semilla. Solo existían tres bases (**n3_s0**, **n3_s1**, **n3_s2**, cada una con 12,000 pasos de entrenamiento de recuperación pura), así que las semillas 0 a 2 entraron a la fase de abstención recuperando ya a RECUP 0,7734, 0,7970 y 0,7725, mientras que las semillas 3 a 8 arrancaron de cero. El preregistro de la campaña afirmaba que solo variaba la semilla, y el chequeo que se hizo en su momento comparó los *configs* guardados, que no registran si hubo siembra.

grupo	semillas	RECUP inicial	desenlace
pre-entrenadas	0, 1, 2	$\approx 0,78$	3 de 3 útiles
desde cero	3 a 8	0	2 útiles, 4 degeneradas

Decimos con todas las letras qué cuesta esto y qué no. **Cuesta la tasa.** “Cuatro de nueve semillas” no es una tasa sobre una población homogénea, y la afirmación honesta es 0 de 3 con pre-entrenamiento y 4 de 6 sin él. **No cuesta el fenómeno**, que se mide por unidad y no depende del agrupamiento. El punto fijo degenerado existe, cuatro unidades están en él, sus cabezas se ubican en el prior y el estado es absorbente.

Y *fortalece* el mecanismo de la sección 4 en vez de debilitarlo. Si el desenlace es una carrera entre el aprendizaje de la recuperación y el asentamiento de la cabeza, entonces un modelo que llega recuperando ya ganó la carrera antes de que empiece, que es exactamente el patrón observado. Que dos de las seis unidades desde cero lleguen igual al punto útil muestra que el pre-entrenamiento no es necesario, solo fuertemente favorable.

Dónde muere esto y dónde no, dicho en las dos secciones afectadas. La sección 5.4 se apoya en un control pareado que comparte semilla *y* base, así que no queda tocada, mientras que la tabulación amplia de 31 contra 9 sí queda confundida y no nos apoyamos en ella.

5.1. Cuatro de nueve unidades terminan mudas

Qué dicen las métricas estándar sobre las filas en negrita. Las cuatro se abstienen en todas las preguntas. Por lo tanto **nose** vale 1,0000, o sea que rechazan correctamente toda pregunta sin respuesta. Y **invento** vale 0,0000, porque nunca nombran contenido ausente del archivo, ya que nunca nombran nada. En los dos números que la literatura de abstención informa, estas son las mejores unidades de la tabla, estrictamente mejores que **b3_s0**, que contesta y por eso ocasionalmente se equivoca.

Su exactitud global es 0,4065, el piso trivial, con cuatro decimales, en las cuatro.

Cuadro 1: Las nueve unidades en su propio punto de operación. RECUP es la recuperación ignorando la cabeza, y las últimas tres columnas describen el comportamiento de la cabeza. Las unidades degeneradas van en negrita.

unidad	paso	RECUP	AUC(a)	$a > 0$	mediana de a	rango de a
b3_s0	26000	0.9996	0.9997	0.407	-7.634	29.17
b3_s1	26000	0.9992	0.9999	0.407	-7.563	29.86
b3_s4	19000	0.7984	0.8084	0.413	-0.157	14.17
b3_s2	26000	0.7946	0.8163	0.392	-0.233	14.23
b3_s5	6000	0.7314	0.7550	0.529	+0.069	5.66
b3_s6	26000	0.3964	0.5734	1.000	+1.006	3.12
b3_s3	26000	0.3820	0.5784	1.000	+1.045	2.83
b3_s7	13500	0.3432	0.5220	1.000	+1.251	1.06
b3_s8	8000	0.3040	0.5458	1.000	+1.507	0.85

Una hipótesis que sostuvimos y refutamos. *vigente* es compuesta, así que *vigente* = 0,0000 es compatible con una recuperación *perfecta* escondida detrás de una cabeza trabada. Eso esperábamos. Es falso. RECUP va de 0,30 a 0,40 en las unidades degeneradas contra 0,73 a 1,00 en el resto. La recuperación está genuinamente dañada.

Pero no es cero, y eso importa para la interpretación. Con $\approx 0,35$ contra una tasa de azar por debajo de 0,01, estos modelos aprendieron una parte sustancial de la tarea y se quedaron a mitad de camino. El estado degenerado no es un modelo sin entrenar. Es un modelo parcialmente entrenado cuya cabeza informa correctamente que ese entrenamiento parcial es insuficiente.

5.2. La cabeza colapsó al prior, y la constante está donde la pone la teoría

Las cuatro cabezas degeneradas no discriminan. Su AUC sobre su propio blanco va de 0,522 a 0,578, contra 0,9997 de **b3_s0**. Tampoco están saturadas en $+\infty$, ya que el rango entero entre los percentiles 1 y 99 de sus logits abarca de 0,85 a 3,24, contra 29,17. Son constantes ubicadas apenas por encima del umbral de decisión.

La ecuación (1) predice *cuál* constante, sin ningún parámetro ajustado.

Cuadro 2: Prior en forma cerrada contra el logit mediano medido. No se ajusta ningún parámetro.

unidad	RECUP	$\mathbb{E}[b]$	logit predicho	mediana medida de a	diferencia
b3_s8	0.3040	0.8196	1.513	1.507	0.006
b3_s7	0.3432	0.7963	1.363	1.251	0.112
b3_s3	0.3820	0.7733	1.227	1.045	0.182
b3_s6	0.3964	0.7647	1.179	1.006	0.173

El ordenamiento se reproduce en las cuatro y la unidad más joven cae a 0,006 de la predicción sin parámetros. Las unidades más viejas quedan apenas por debajo de su prior, que es lo que haría una cabeza que empieza a discriminar, y de manera consistente con eso el rango de a crece de forma monótona con el paso a lo largo de las cuatro (0,85, luego 1,06, luego 2,83, luego 3,12). **La cabeza no está rota. Es óptima para un generador que se equivoca el 80 % de las veces.**

5.3. La bifurcación se decide en el paso 2500

Toda unidad con este blanco pasa por una fase muda inicial, cosa esperable, porque en la inicialización el blanco es la constante 1. Lo que cambia es si esa fase termina.

El bucle de entrenamiento ya evalúa sobre 8 lotes de 64, o sea 512 muestras. En el paso 2500 tenemos lo siguiente.

Cuadro 3: Respuestas emitidas sobre 512 en el paso 2500, contra el desenlace final.

unidad	abstencion @2500	respuestas emitidas	desenlace
b3_s2	0.9844	8	útil
b3_s0	0.9922	4	útil
b3_s5	0.9922	4	útil
b3_s1	0.9961	2	útil
b3_s4	0.9980	1	útil
b3_s3	1.0000	0	degenerada
b3_s6	1.0000	0	degenerada
b3_s7	1.0000	0	degenerada
b3_s8	1.0000	0	degenerada

La separación es cero contra no cero, y **b3_s4** sobrevive con una **sola muestra de 512** y llega a **vigente** = 0,68. Romper el silencio una vez parece ser el evento que importa, que es lo que predice la carrera de la sección 4. Una muestra en la que el **argmax** acierta es una muestra cuyo blanco vale 0, y eso es justamente lo que una cabeza constante no tiene gradiente para producir.

Validación sobre el repositorio. Aplicada a **todas** las corridas de este repositorio con cabeza binaria de abstención que llegaron a ≥ 6000 pasos y tienen checkpoint en el paso 2500, o sea 40 corridas, doce familias, dos reglas de decisión y los dos blancos, la regla separa **40 de 40**. Son 36 predichas útiles y útiles, y 4 predichas degeneradas y degeneradas.

La prueba más dura disponible, corrida después de formular la regla. La regla se derivó post hoc. Después llevamos las dos unidades degeneradas *más viejas* al horizonte completo con las banderas originales, preregistrando la predicción de que ninguna saldría de la abstención total. Ninguna salió. **b3_s3** y **b3_s6** llegaron al paso 26000 con **abstencion** $\geq 0,999$ en todos los hitos registrados. No es una validación prospectiva, porque la prueba propiamente prospectiva habría sido un diseño de barrido que no corrimos, pero es la prueba más fuerte que permitían las unidades existentes y la regla la sobrevivió.

Una advertencia sobre el margen. Una muestra en 512 es un margen del 0,2%. Como criterio operativo la *tasa* de abstención es demasiado frágil, y la forma robusta de la misma cantidad es $\min_i a_i$ sobre un lote grande, que es continua e independiente del tamaño del lote.

5.4. La fase muda pertenece al blanco autorreferencial

Esta es la sección que más toca el confundido de la siembra, así que enunciamos **primero el límite**. Toda corrida con blanco fijo de este repositorio usa las semillas 0 a 2, y esas son exactamente las semillas para las que existe una base pre-entrenada. La tabulación amplia que sigue queda entonces confundida con la inicialización, y la informamos como descripción y no como evidencia.

blanco	corridas	abstencion en el paso 2500
fijo (“¿existe la respuesta?”)	31	0,02 a 0,32
autorreferencial (“¿me voy a equivocar?”)	9	0,98 a 1,00

La afirmación se apoya en cambio en el control pareado, al que el confundido no llega. Las tres unidades p3 comparten semilla, arquitectura, presupuesto *y* base pre-entrenada con b3_s0, b3_s1 y b3_s2, y difieren solamente en el blanco.

semilla	abstencion @2500, blanco fijo	abstencion @2500, autorreferencial
0	0.086	0.992
1	0.201	0.996
2	0.063	0.984

Tres de tres, con la variable confundida fijada por construcción. El blanco autorreferencial mete al modelo en la fase muda *incluso cuando llega recuperando* a $\text{RECUP} \approx 0,78$, y el blanco fijo no lo hace nunca. Las unidades p3 terminan con RECUP de 0,80 a 0,97 y ninguna cae en la banda degenerada.

El mecanismo es el que nombra la sección 4. Un blanco fijo es observable desde el paso 1 y discriminativo de entrada, así que su cabeza nunca pasa por la fase constante en la que la solución degenerada está disponible.

5.5. El punto degenerado es absorbente y no lento

Que el estado sea un punto fijo o un cuello de botella lento cambia por completo lo que se sigue de él, y los dos se distinguen midiendo la recuperación *dentro de una misma unidad*, cosa que esta línea de trabajo nunca había hecho, porque los checkpoints intermedios se sobrescriben y la **vigente** registrada vale 0,0000 en todos los hitos sin importar la recuperación.

Archivamos cada checkpoint parcial de b3_s3 desde 22000 hasta 26000 y medimos RECUP en cada uno con muestras pareadas ($n = 8000$, semilla 54321), bajo un preregistro congelado de antemano que pedía $\geq +0,0100$ y monotonía en ≥ 3 de 4 intervalos.

paso	22000	23000	24000	25000	26000
RECUP	0.3841	0.3778	0.3844	0.3812	0.3820

El total es **-0,0021** a lo largo de 4000 pasos. Con $p_{\text{flip}} = 0,1526$ medido, el desvío estándar pareado es 0,0057, así que el total vale $0,4\sigma$ y cada intervalo queda entre $0,1$ y $1,2\sigma$, o sea **ruido alrededor de una línea plana**. La monotonía dio 2 de 4. El criterio de riesgo del preregistro se disparó y se aplicó su cláusula de abandono, con lo cual se canceló una campaña de seguimiento de 70000 pasos que estaba planificada.

Qué no separa esto, declarado de antemano. Los últimos 4000 pasos corren con la tasa de aprendizaje en el piso de su cronograma coseno. “El atractor es absorbente” y “nada se mueve con la tasa de aprendizaje en el piso” son las dos compatibles con una curva plana, y la campaña cancelada era la que las habría separado. Por eso enunciamos el resultado como *absorbente bajo este presupuesto y este cronograma*, y no como absorbente en general. Esta es la principal pregunta abierta que deja el trabajo.

Un intervalo apunta al revés. b3_s6, al que le quedaban solo 1000 pasos, da $+0,0080$ ($1,6\sigma$). El preregistro ya había dictaminado que un intervalo suelto no constituye tendencia, y no la constituye, pero es la única medición de este trabajo que empuja en dirección contraria y la informamos como tal.

5.6. Una corrección a nuestra propia primera lectura

Nuestro primer análisis ajustó una recta a través de las cuatro unidades degeneradas ordenadas por paso y extrapoló que RECUP llegaría a 0,70 hacia los 84000 pasos, o sea que el estado era lento y no absorbente. Antes de publicar esa lectura se corrieron dos chequeos, y el segundo la dio vuelta.

El chequeo que pasó. La medición inicial usaba $n = 2000$, cuyo $\sigma = 0,0135$ es comparable a la dispersión entre unidades, así que sospechamos que la tendencia era ruido de medición. Volver a medir las cuatro con $n = 8000$ da $r = 0,9864$ con un rango de $12,5\sigma$. **La tendencia es real y la sospecha estaba equivocada.**

El chequeo que falló. La tendencia es real pero no es lineal. Las pendientes por intervalo decrecen de forma monótona, con $+0,0071$, $+0,0048$ y $+0,0014$ por cada 1000 pasos entre unidades sucesivas, y $-0,0005$ dentro de `b3_s3`, y un ajuste con saturación da una suma de cuadrados residual 12,6 veces menor que el lineal. La extrapolación era un artefacto de ajustar una recta a una curva cóncava.

Qué no concluimos del ajuste con saturación. Tiene tres parámetros para cuatro puntos, y su propia predicción en el paso 26000 (0,4535) le erra al valor medido (0,3820) por 0,07. No es evidencia. La afirmación de la sección 5.5 se apoya en la medición dentro de una misma unidad, que no tiene confundido entre semillas, y el ajuste con saturación solo explica por qué la extrapolación anterior estaba mal.

6. Lo que no afirmamos

Esto no es evidencia de que el blanco autorreferencial sea inútil. Cinco de nueve unidades llegan a un estado útil, dos de ellas con $\text{RECUP} \geq 0,999$ y $\text{AUC} \geq 0,9999$. La afirmación es que el objetivo admite una segunda solución estable y que una minoría sustancial de semillas la encuentra, no que el objetivo fracase.

Las unidades degeneradas no están mal calibradas. Sería cómodo llamarlas rotas. No lo están. Sus cabezas son óptimas para sus generadores, con 0,006 de diferencia contra la predicción sin parámetros en el caso más limpio. La falla es que estar bien calibrado sobre no saber nada no vale nada, que es una afirmación sobre el objetivo y las métricas, no sobre la calibración.

No afirmamos que el modelo sepa cuándo no sabe. Todo acá es supervisado. La cabeza se entrena contra etiquetas, y en el caso autorreferencial contra etiquetas derivadas de una comparación supervisada. Las unidades degeneradas en particular son una advertencia contra esa lectura, porque exhiben la firma externa de saber cuándo no saben mientras no saben absolutamente nada.

La regla del paso 2500 es post hoc. Se formuló después de observar los desenlaces, se validó sobre 40 corridas existentes y se puso a prueba en dos unidades llevadas al horizonte completo bajo preregistro. Eso es evidencia retrospectiva fuerte más una confirmación dura. No es una validación prospectiva y no la informamos como tal.

7. Limitaciones

- **El punto de partida no estuvo controlado, y lo encontramos tarde.** Las semillas 0 a 2 heredaron 12,000 pasos de pre-entrenamiento de recuperación y las semillas 3 a 8 no,

así que el reparto del titular no es una tasa sobre una población homogénea (sección 5.1). Los fenómenos por unidad no quedan afectados y el control pareado de la sección 5.4 está limpio, pero cualquier campaña futura sobre esta pregunta tiene que fijar la inicialización en todas las unidades, y el arnés tiene que registrar si hubo siembra, cosa que el config guardado no hace y por eso el chequeo original no lo vio.

- **Escala.** Son 863,730 parámetros, un idioma sintético de 242 tokens, un solo nivel de dificultad y p_{nose} fijo en 0,4. Nada de esto transfiere automáticamente. Solo señalamos que el punto fijo degenerado es una propiedad del álgebra del objetivo antes que del tamaño del modelo, lo que vuelve la pregunta por la transferencia digna de hacerse, no respondida.
- **El presupuesto y el cronograma están confundidos con la afirmación de que es absorbente,** como se declara en la sección 5.5. Es el hueco más grande del trabajo.
- **Nueve unidades.** El reparto 5 y 4 es un conteo y no una estimación de tasa. Lo informamos como observado y no le adosamos un intervalo de confianza a una proporción salida de nueve semillas.
- **Dos unidades están incompletas.** b3_s7 y b3_s8 se detuvieron en los pasos 13500 y 8000, después de que el criterio bloqueante de la campaña se volviera aritméticamente inalcanzable. Su condición degenerada en esos pasos está medida y no extrapolada, pero no corrieron hasta el horizonte, y el desvío está declarado en el repositorio.
- **Una sola regla de decisión.** Todas las unidades usan la cabeza binaria separada. Si las interfaces de token o de slot admiten el mismo punto fijo bajo un blanco autorreferencial es algo que no está probado.
- **Búsqueda bibliográfica dirigida, no revisión sistemática.**

8. Conclusión

Un detector de alucinaciones quiere predecir los errores de su propio modelo, así que el blanco natural es autorreferencial. Ese blanco tiene dos puntos fijos estables, y el degenerado no es una patología para sacarse de encima por ingeniería sino una solución correcta. Es un modelo que no recupera casi nada y que informa, con exactitud, que no recupera casi nada. Cuatro de las seis unidades que empezaron desde cero lo encontraron, y ninguna de las tres que empezaron recuperando.

Lo que hace que esto sea más que una curiosidad es que la solución degenerada es **invisible para las métricas que el campo informa**. Puntúa `nose` = 1,0000 e `invento` = 0,0000, mejor que las unidades que funcionan, mientras su exactitud global queda en el piso trivial con cuatro decimales. Cualquier criterio armado con tasa de abstención y tasa de fabricación queda maximizado por ella. El remedio no es sutil, y consiste en informar la exactitud global contra su piso trivial y exigirla junto a cualquier métrica de abstención, pero hay que aplicarlo, y en este proyecto se aplicó recién después de que una campaña ya estuviera diseñada alrededor de criterios que un modelo mudo habría ganado.

La bifurcación es legible temprano y barata de leer. Cero respuestas emitidas en el paso 2500 separó 40 de 40 corridas, y una unidad sobrevivió con una muestra de 512. Si esa regla generaliza, cosa que este trabajo no establece, entonces la pregunta relevante para un objetivo de abstención autorreferencial no es cómo hacer que un modelo se abstenga bien. Abstenerse bien es trivial, y un modelo puede lograrlo no sabiendo nada. La pregunta es cómo salir del silencio sin empezar a inventar, y eso se decide en los primeros pocos miles de pasos.

Disponibilidad de datos y código

Todos los preregistros con sus hashes SHA, los archivos de desvíos, los scripts de análisis, los resultados crudos por semilla y los informes generados automáticamente están archivados en el repositorio del proyecto, <https://github.com/SperanzaMax/delta-archivo>, cuyo historial de commits lleva las marcas de tiempo que establecen el orden entre preregistro y resultado.

Declaraciones

Financiamiento. Ninguno. **Conflictos de interés.** Ninguno. **Aprobación ética.** No aplica, no hay sujetos humanos ni animales. **Disponibilidad de datos.** Ver más arriba. **Contribuciones de autoría.** Autor único.

Referencias

- Arazo, E., Ortego, D., Albert, P., O'Connor, N. E., and McGuinness, K. (2020). Pseudo-labeling and confirmation bias in deep semi-supervised learning. *IJCNN*.
- Chen, X. and He, K. (2021). Exploring simple Siamese representation learning. *CVPR*.
- Cohen, R., Dobler, K., Biran, E., and de Melo, G. (2024). I don't know: Explicit modeling of uncertainty with an [IDK] token. *NeurIPS*.
- El-Yaniv, R. and Wiener, Y. (2010). On the foundations of noise-free selective classification. *JMLR*, 11:1605–1641.
- Geifman, Y. and El-Yaniv, R. (2017). Selective classification for deep neural networks. *NeurIPS*.
- Geifman, Y. and El-Yaniv, R. (2019). SelectiveNet: A deep neural network with an integrated reject option. *ICML*.
- Grill, J.-B. et al. (2020). Bootstrap your own latent: A new approach to self-supervised learning. *NeurIPS*.
- Speranza, M. (2026). Where abstention lives: A pre-registered four-way comparison of abstention interfaces in a small language model with versioned memory. *Research Square*, DOI 10.21203/rs.3.rs-10839567/v1.