

La indexación geométrica no mejora la recuperación de memoria versionada: tres resultados negativos pre-registrados y un modo de fallo total silencioso

Maximiliano Speranza
Investigador independiente, Buenos Aires, Argentina
[ORCID: 0009-0005-0413-8554](https://orcid.org/0009-0005-0413-8554)
maximiliano.speranza@gmail.com

Agosto de 2026

Resumen

Se espera cada vez más que un agente conversacional recuerde lo que un usuario le dijo a lo largo de varias sesiones, incluido el caso en que ese usuario *corrige* algo dicho antes. Una propuesta natural es aprovechar la geometría del espacio de embeddings: en lugar de sobrescribir un recuerdo, depositar la versión revisada *cerca* de su predecesora, de modo que la cercanía codifique la relación entre versiones. Este trabajo pone a prueba esa propuesta de manera directa, sobre un índice no paramétrico con un codificador congelado, con cada predicción registrada y congelada por hash **antes** de que existieran los datos correspondientes.

El resultado es un negativo consistente y con mecanismo identificado. Con paso de desplazamiento fijo, el conjunto de revisiones ejecuta una caminata no acotada que se aleja de su ancla: el coseno contra la consulta cae de 0,811 a 0,324 tras cuatro revisiones y a $-0,139$ tras seis, y la cobertura se desploma a 0,000 desde $K \geq 4$. Acotar el desplazamiento **repara la deriva exactamente como se pretendía** — el coseno queda plano en 0,8177, con pendiente $+0,0000$ por revisión — y el mecanismo *igual* pierde, por $-0,0864$ (IC95 $[-0,1014, -0,0714]$) con $K = 8$. La razón es un peaje constante de $\approx 0,036$ de coseno: el embedding del texto real de esa versión ya está óptimamente colocado, porque contiene la entidad que la consulta menciona, de modo que cualquier desplazamiento artificial sólo puede alejarlo.

Esa última cláusula es una propiedad del *generador*, no de las correcciones. Las correcciones conversacionales reales son elípticas: «no, es Beto» no nombra la entidad. Por eso se corrió un tercer experimento adversarial en el régimen que debería favorecer a la geometría, contra la línea de base honesta (hidratación por co-referencia, tal como la implementan los sistemas en producción), barriendo su tasa de error τ . La geometría sólo gana por encima de $\tau^* \approx 0,45$ — un resolutor de co-referencia peor que una moneda — de modo que el negativo se **extiende** en lugar de revertirse.

El hallazgo positivo utilizable no depende del mecanismo puesto a prueba: **las correcciones elípticas crudas son irrecuperables, con 0,0000 de recuperación en $k = 5$ en las diez semillas** — no bajas: nunca. Un sistema de memoria que archive turnos conversacionales sin resolver la co-referencia pierde el **100 % de las correcciones**, y las pierde en silencio: el índice siempre devuelve algo, sólo que nunca lo correcto.

Palabras clave: memoria conversacional, generación aumentada por recuperación, actualizaciones de conocimiento, geometría de embeddings, pre-registro, resultados negativos, resolución de co-referencia

1. Introducción

El objetivo que motiva este trabajo se enuncia en una frase: *que un modelo de lenguaje no olvide nunca lo que le dijo*. El énfasis está en *dijo*. Retener lo que un modelo *leyó* — documentos

largos, contextos amplios, una base de conocimiento — es un campo concurrido y con enormes recursos detrás. Retener lo que una persona concreta *dijo*, a través de sesiones, e incluyendo el caso en que después lo *corrige*, es un problema estructuralmente distinto: persiste más allá del paso hacia adelante, pertenece a una persona y no a un corpus, y tiene versiones. Un corpus no se contradice a sí mismo; una conversación sí, todo el tiempo.

La tarea canónica de ese objetivo es un hecho versionado: «*el director de X es Ana*», luego «*no, es Beto*», y después «*¿quién dirige X?*». Es exactamente lo que la categoría **knowledge updates** de LongMemEval [1] mide a nivel de sistema. Nuestro aporte no es la tarea sino el **instrumento**: aislamos el **mecanismo de indexación** con todo lo demás fijo, algo que un benchmark de sistema completo no puede hacer.

El mecanismo puesto a prueba es lo que llamamos **gemación**: cuando un recuerdo se revisa, no se sobrescribe — se deposita la versión nueva en una dirección *cercana*, de modo que la cercanía misma codifique la correlación entre versiones. Su linaje es honorable: la memoria distribuida dispersa de Kanerva [6] escribe en direcciones vecinas y lee el vecindario, y el Differentiable Neural Computer [7] resuelve el enlace temporal con una matriz $N \times N$, que es justamente por lo que no escaló. El aporte de la gemación, si funcionara, sería que **la geometría reemplaza a la matriz de enlaces** — $O(1)$ por escritura en vez de $O(N^2)$.

No funciona. Este trabajo informa por qué, en tres experimentos pre-registrados, y presenta el único hallazgo que sobrevivió y que resulta útil para quien construye estos sistemas.

1.1. Aportes

1. Un negativo pre-registrado para la indexación geométrica de memoria versionada, replicado en **tres regímenes** — desplazamiento de paso fijo, desplazamiento acotado y correcciones elípticas — con un mecanismo distinto identificado en cada uno (secciones 4, 5 y 6).
2. Una **prueba adversarial de nuestra propia conclusión**: el tercer régimen se diseñó específicamente para favorecer al mecanismo, quitándole la propiedad que explicaba su fracaso en el segundo. Aun así perdió.
3. Un punto de cruce cuantitativo: el anclaje geométrico sólo supera a la hidratación por co-referencia cuando ésta falla en el $\tau^* \approx 0,45$ de las correcciones o más.
4. Un hallazgo independiente y accionable: **las correcciones elípticas crudas nunca se recuperan** (0,0000 en $k = 5, 10$ de 10 semillas; top-1 en el azar en una verificación aparte), de modo que archivar turnos conversacionales sin resolución de co-referencia pierde todas las correcciones, en silencio.
5. Dos resultados metodológicos: una **compuerta de admisión de codificadores** en cuatro partes que habría ahorrado dos noches de trabajo, y un caso de estudio sobre **una media que esconde su distribución** — el tercero en este programa de investigación.

2. Trabajo relacionado

Benchmarks. LongMemEval [1] define cinco habilidades para la memoria conversacional de largo plazo, de las cuales *knowledge updates* — un hecho enunciado en una sesión se cambia en otra posterior — es precisamente nuestra tarea. Mide sistemas completos (modelo + memoria + prompt), donde no se puede aislar de dónde viene un efecto. Trabajamos deliberadamente un nivel más abajo. Por lo tanto no reclamamos la tarea como novedosa: es una instancia sintética y controlada de una categoría que ya tiene benchmark, y nuestro aporte es el aislamiento de un componente dentro de ella.

Resolución de conflictos en sistemas desplegados. Graphiti/Zep invalida un hecho superado pero conserva el registro histórico con una ventana de validez. REMem [3] construye un grafo de memoria híbrido con *gists* y hechos con marca temporal. NeuSymMS [4] cura una memoria neuro-simbólica para agentes persistentes, y Supersede [5] diagnostica y entrena el *memory-update gap*. Mem0 y Letta ofrecen memoria como servicio. Todos operan en la *capa de aplicación*: grafos, metadatos, punteros explícitos, invalidación simbólica. Ninguno mete el índice *adentro* de la red.

Frescura determinista. Una línea reciente [2] sostiene que resolver conflictos de memoria no debe delegarse al criterio del modelo sino a una regla determinista. Nuestras propias mediciones geométricas convergen en el mismo dictamen de diseño por una vía independiente — *geometría para agrupar, metadato para ordenar* — y por eso nuestros negativos son una confirmación independiente y cuantificada de esa posición, no un competidor.

Linaje del mecanismo bajo prueba. La gemación desciende de la memoria distribuida dispersa de Kanerva [6], cuya operación de lectura es formalmente cercana a la atención softmax [8]. El Differentiable Neural Computer [7] resuelve el enlace temporal con una matriz de enlaces explícita de $N \times N$, que es exactamente el costo que la gemación busca evitar dejando que la geometría cargue con la relación.

Índices de recuperación dentro de la red. Memorizing Transformers [10] adosan una memoria k NN no diferenciable; Memory Layers [11] entrenan el índice pero con valores paramétricos en lugar de contenido recuperado; HOLA [12] y Hybrid Associative Memories [13] combinan un estado recurrente con un caché exacto acotado. Todos ellos viven *dentro* de una secuencia: su memoria nace y muere en el paso hacia adelante. La persistencia entre sesiones — nuestro escenario — queda para la capa de aplicación, y los dos obstáculos para cerrar esa brecha son que el gradiente no fluye por la selección top- k y que un índice congelado queda obsoleto a medida que el codificador se mueve [9, 14].

Sobre los números publicados. En LongMemEval con GPT-4o se reporta Zep 63,8 % contra Mem0 49,0 %, mientras que Mem0 informa 94,4 % bajo otra configuración. La discrepancia es metodológica, no una diferencia de capacidad. Es exactamente la situación que motiva medir un mecanismo aislado en un banco controlado.

3. Método

3.1. Tarea

$N = 3000$ entidades sintéticas, cada una con un atributo tomado de cinco plantillas (*director, sede, fundador, ingeniero jefe, proveedor principal*), un valor de la reserva de ese atributo y una consulta en lenguaje natural («¿quién dirige Helios Laboratory?»). Una revisión asigna un valor nuevo a la misma entidad. El índice almacena direcciones; una consulta recupera los k primeros ($k = 5$) por similitud coseno.

Tres métricas, calculadas por semilla y agregadas con intervalos de confianza del 95 % por t de Student con 9 grados de libertad (10 semillas $\times$ 1000 entidades submuestreadas):

- **VIGENTE:** la entrada con la última revisión está entre las k primeras.
- **ANTERIOR:** la entrada con la revisión previa está entre las k primeras.
- **COBERTURA:** ambas lo están, simultáneamente.

3.2. Condiciones

- **sin:** sin archivo. Control de piso.
- **sobrescritura:** la revisión reemplaza al original. La versión vieja se pierde por construcción; su puntaje en ANTERIOR debe ser 0, y ése es nuestro control de validez de la tarea.
- **duplicados:** ambas versiones almacenadas en el embedding real de su propio texto. Es la línea de base que la gemación debe superar.
- **gemacion:** el *contenido* de la revisión almacenado en una dirección *anclada* al original: $\hat{v} = \text{normalizar}(E_0 + \varepsilon t)$, con t una tangente unitaria aleatoria a E_0 y $\varepsilon = 0,30$ heredado de mediciones geométricas previas y nunca reajustado.

3.3. Protocolo de pre-registro

Cada predicción, umbral y cláusula de falsación de este trabajo fue escrita y **congelada con un hash SHA-256 antes de que existieran los datos correspondientes**. Los hashes están registrados en PREREG_HASH.txt, con sus marcas de tiempo en el historial de commits del repositorio. Tres propiedades del protocolo conviene enunciarlas de manera explícita, porque son las que hacen interpretables a los negativos:

1. **Margen efectivo fijado de antemano.** Una diferencia cuenta sólo si supera 0,02 en valor absoluto y su intervalo de confianza no cruza el cero.
2. **Controles bloqueantes primero.** Cada experimento declara un control cuyo fallo anula el resto. Se evalúan antes que la predicción principal, y el script de análisis aborta si alguno falla.
3. **Falsación comprometida por adelantado.** Cada pre-registro enuncia qué conclusión se sigue si la predicción principal falla, *incluido* el compromiso de cerrar la línea en lugar de probar otra variante.

3.4. Compuerta de admisión de codificadores

Antes de generar dato alguno, el codificador debe pasar cuatro chequeos. Esta compuerta existe porque su ausencia costó dos noches de trabajo sobre un fallo mal diagnosticado, y una sola de sus líneas lo habría detectado de inmediato:

1. **C1: censo de vectores únicos.** ¿Cuántos vectores distintos produce el corpus?
2. **C2: discriminación de valores.** ¿Difieren dos versiones del mismo hecho?
3. **C3: discriminación de entidades.** ¿Difieren dos entidades distintas?
4. **C4: identificación por top-1 y por rango, nunca por AUC.**

C4 no es pedantería. En un intento fallido, un AUC de 0,97 convivía con un top-1 de 0,13: la distribución de puntajes separaba bien en promedio mientras el ítem correcto casi nunca quedaba primero. El AUC es el instrumento equivocado para una compuerta de recuperación.

Un fallo concreto de codificador. `nomic-embed-text` servido por Ollama colapsa *todo token* capitalizado a un mismo vector. Coseno medido entre nombres propios sin relación:

par	con mayúscula	en minúscula
Helios / Vantor	1,000000 (idéntico bit a bit)	0,407
Ana / Beto	1,000000	0,349
cat / dog (control)	0,603	0,603

No es un artefacto del endpoint (se reprodujo en `/api/embeddings` y `/api/embed`, suelto y en lote) ni algo específico de la máquina. Explica un corpus previo que producía apenas 75 vectores únicos entre 3000 — exactamente 5 atributos $\times$ 15 sufijos numéricos, lo único no capitalizado que variaba. **El arreglo es pasar el texto a minúscula** antes de codificar, tras lo cual la compuerta abre: 400 de 400 vectores únicos, top-1 0,975, rango mediano 0. Todos los experimentos siguientes usan texto en minúscula.

4. Experimento 1: gemación con paso fijo

4.1. Una sola revisión

Con una revisión por entidad, todas las condiciones con archivo quedan en el techo:

condición	VIGENTE	ANTERIOR	COBERTURA
sin	0,0000	0,0000	0,0000
sobrescritura	1,0000	0,0000	0,0000
duplicados	0,9992	0,9988	0,9988
gemacion	0,9928	0,9928	0,9928

P1 (principal) no confirma: gemación – duplicados en COBERTURA = $-0,0060$, IC95 $[-0,0077, -0,0043]$, contra un requisito de $+0,02$.

P2 (control) pasa: sobrescritura obtiene exactamente 0,0000 en ANTERIOR, de modo que la tarea mide lo que dice medir. **P3 pasa:** anclar no cuesta nada sobre la recuperación del valor al día ($-0,0072$, con piso $-0,02$).

Insistimos en la lectura correcta: con ambas condiciones por encima de 0,99, éste es un **negativo sin potencia**, no una demostración de equivalencia. Ese techo es lo que motivó el experimento 1b.

4.2. Escalar el número de revisiones

Poblar el clúster obliga a la geometría a trabajar. COBERTURA en función de K revisiones:

K	duplicados	gemacion	diferencia
1	0,9991	0,9949	$-0,0042$ $[-0,0050, -0,0034]$
2	0,9914	0,0567	$-0,9347$ $[-0,9390, -0,9304]$
4	0,9482	0,0000	$-0,9482$ $[-0,9537, -0,9427]$
8	0,2822	0,0000	$-0,2822$ $[-0,2912, -0,2732]$

El mecanismo, medido. Coseno de la entrada vigente contra la consulta, por índice de revisión:

r	gemacion (paso fijo)	duplicados (texto real)
0	0,8106	—
1	0,7777	0,7887
2	0,6792	0,7683
4	0,3235	0,8064
6	-0,1391	0,8187
8	-0,1391	0,8015

Con un paso ε fijo por revisión, el clúster ejecuta una **caminata no acotada**: el arco crece sin límite ($\approx 0,30$ rad por paso; $2,36$ rad en $r = 8$), de modo que desde $r \approx 4$ la entrada vigente queda más lejos de la consulta que un distractor cualquiera y deja de entrar al top- k . En **duplicados**, en cambio, cada revisión es el embedding real de su propio texto y se mantiene en $\approx 0,80$ para todo r : no hay deriva porque no hay desplazamiento inducido.

No es un artefacto: es una propiedad de la gemación *tal como está especificada*, con ε fijo y explícitamente no reajustable según el pre-registro.

5. Experimento 2: gemación acotada

Si el problema es la deriva no acotada, acotarla debería alcanzar. Pre-registramos una variante, **orbita**, en la que cada revisión se coloca a distancia ε del *ancla original* en lugar de la revisión previa, de modo que el desplazamiento no pueda acumularse. Se incluyeron como controles una variante de paso decreciente y la condición original de paso fijo.

La reparación funciona exactamente como se diseñó. P-A4 (mecanicista): la pendiente del coseno por revisión es $+0,0000$ para **orbita** contra $-0,1410$ del paso fijo; **orbita** queda plana en $0,8177$ para todo K . El control bloqueante P-A3 también pasa: el paso fijo reproduce su colapso ($0,0000$ en $K = 4$), de modo que el banco es comparable entre campañas.

Y el mecanismo pierde igual. P-A1 (principal): COBERTURA en $K = 8$, **orbita** — **duplicados** = **-0,0864**, IC95 $[-0,1014, -0,0714]$. Pierde en los cuatro valores de K .

K	orbita	decay	fija	duplicados
1	0,9946	0,9946	0,9946	0,9991
2	0,9747	0,6805	0,0546	0,9914
4	0,8628	0,0282	0,0000	0,9482
8	0,1958	0,0000	0,0000	0,2822

Por qué. La tabla de cosenos lo dice en una línea: **duplicados** está en $0,8540$ y **orbita** en $0,8177$. Las dos son planas. La diferencia es un **peaje constante de** $\approx 0,036$ que se paga por desplazar la entrada ε del ancla, y ese peaje alcanza para perder la competencia del top- k contra entradas de otras entidades.

La razón de fondo es que $\text{emb}(v_r)$ — el embedding del texto real de esa versión — **ya está óptimamente colocado**, porque contiene la entidad que la consulta menciona. Cualquier desplazamiento artificial, por acotado que sea, sólo puede alejarlo. *La geometría no tenía nada que agregar: el codificador ya había puesto cada versión donde correspondía.*

Según la cláusula de falsación comprometida por adelantado, la gemación quedó cerrada como mecanismo de indexación sin probar una tercera geometría.

6. Experimento 3: correcciones elípticas

6.1. La objeción a nuestra propia conclusión

El argumento de cierre de la sección 5 se apoya en una propiedad del *generador*, no de las correcciones. Nuestro generador construye cada revisión como una plantilla completa, entidad incluida. Las correcciones conversacionales reales son **elípticas**: «no, es Beto», «perdón, quise decir Beto». No nombran la entidad, porque el interlocutor ya la conoce.

En ese régimen el argumento se invierte: si el texto no lleva la clave de recuperación, el codificador *no puede* colocarlo cerca de la consulta, y la geometría sería la única fuente disponible de esa clave. Por eso pusimos a prueba nuestra propia conclusión allí donde debía fallar.

Verificación de viabilidad. Coseno contra la consulta, $N = 3000$: revisión auto-contenida 0,8541; revisión elíptica 0,4247. Una corrección elíptica perteneciente a una entidad *distinta* obtiene 0,4064, estadísticamente indistinguible de la correcta. En un piloto más chico ($N = 60$), el top-1 de la corrección elíptica correcta fue 0,0167, es decir exactamente la tasa del azar 1/60.

6.2. La línea de base honesta

En este régimen el rival **no** es **duplicados** a secas, que ya sabemos que falla. Es **duplicados + hidratación por co-referencia**: reescribir «no, es Beto» como «el director de Helios es Beto» *antes* de archivar, que es lo que hacen los sistemas desplegados y que pueden hacer a bajo costo, porque en el momento de escribir tienen la conversación a mano.

Por eso barrimos la tasa de error τ del hidratador: cada entrada se almacena hidratada con probabilidad $1 - \tau$ y cruda con probabilidad τ . Nótese que $\tau = 0$ reproduce exactamente el régimen de la sección 5, lo que nos da un control bloqueante de comparabilidad.

6.3. Resultados

VIGENTE en $K = 8$:

τ	0,00	0,05	0,10	0,40	1,00
hidratada $_{\tau}$	0,5414	0,5368	0,5312	0,4884	0,0000
orbita (plana)			0,4723		

P-E0 (bloqueante) pasa: en $\tau = 0$ la hidratación le gana a la órbita por +0,0691 [+0,0587, +0,0795], reproduciendo el peaje medido en la sección 5.

P-E2 (control de régimen) pasa, y es el número más útil del trabajo: las correcciones elípticas crudas obtienen **0,0000**, con un intervalo de confianza de exactamente [0,0000, 0,0000] en las diez semillas. No *bajas*: *nunca*.

P-E3 (mecanicista) pasa: el coseno de la entrada almacenada cae linealmente en τ con pendiente $-0,4291$ (predicha: $-0,426$), mientras que **orbita** queda plana en 0,8177.

P-E1 (principal) no confirma. Exigíamos un cruce en $\tau^* \leq 0,25$. Una grilla más fina, corrida después del veredicto y reportada como exploratoria, lo ubica entre $\tau = 0,40$ ($-0,0161$) y $\tau = 0,50$ ($+0,0349$): $\tau^* \approx \mathbf{0,45}$.

Enunciado práctico. El anclaje geométrico vale su peaje sólo si el resolutor de co-referencia falla en el **45 % o más** de las correcciones, es decir peor que una moneda. Ningún sistema desplegado está en ese régimen. El negativo, por lo tanto, *se extiende* al régimen diseñado para favorecer al mecanismo, en lugar de quedar confinado al texto auto-contenido.

6.4. El hallazgo que sobrevive

Con independencia de la gemación: **un sistema de memoria que archive turnos conversacionales sin resolver la co-referencia pierde el 100 % de las correcciones.** El fallo es total (0,0000, 10 de 10 semillas) y **silencioso**: el índice siempre devuelve cinco candidatos, ordenados con confianza, ninguno correcto. No hay señal de error, ni resultado vacío, ni bandera de baja confianza — la corrección correcta está en 0,4237 y la de un desconocido en 0,4064.

Es medible, barato de verificar, y aplica a todos los sistemas de la tabla de la sección 2.

Nota estructural. Una corrección elíptica no lleva información de la entidad por construcción, de modo que el espacio de textos posibles es diminuto: cuatro formulaciones $\times$ 60 valores distintos = **240 cadenas posibles** para 24 000 entradas almacenadas. Dos entidades distintas corregidas al mismo valor producen vectores *idénticos bit a bit*. Esa degeneración no es un artefacto de nuestro diseño: es la forma aritmética del fenómeno bajo estudio, y es la razón por la que los empates exactos debieron romperse explícitamente en el código de ordenamiento en lugar de darse por inexistentes.

7. Un resultado metodológico: las medias esconden distribuciones

El pre-registro consignó una predicción *puntual*, $\tau^* \approx 0,075$, derivada de un modelo lineal de las curvas de coseno. El mecanismo de cosenos se comportó exactamente como se predijo — P-E3 pasa, con pendiente $-0,4291$ contra $-0,426$ predicha — y el cruce *igual* cayó en 0,45, seis veces más tarde.

La razón merece enunciarse porque generaliza. **hidratada _{τ}** no se degrada de manera uniforme: cada entrada queda **intacta** (0,854) o **arruinada** (0,42), nunca en el medio. La *media* cruza a *órbita* en $\tau \approx 0,08$, pero el top- k se decide entrada por entrada, y con $\tau = 0,10$ el noventa por ciento de las consultas todavía tiene su entrada perfectamente colocada. La órbita, en cambio, paga su peaje en *todas*.

Un efecto de segundo orden empuja en la misma dirección: a medida que las entradas competidoras se degradan, dejan de competir por el top- k , lo que *ayuda* a la entrada sana. Por eso **hidratada_{0,40}** obtiene 0,4884 y no el $0,6 \times 0,5414 = 0,325$ que predeciría un modelo multiplicativo.

Regla práctica: cuando una predicción se deriva de un promedio, hay que revisar la forma de la distribución antes de creerle al número. Éste es el tercer caso de una media que esconde su distribución en este programa de investigación.

8. Limitaciones

1. **Índice no paramétrico sobre codificador congelado.** Nada de lo aquí medido dice algo sobre un índice **co-entrenado dentro de la red**, donde las direcciones serían representaciones aprendidas y no embeddings de texto fijos, y donde «el codificador ya lo puso donde corresponde» deja de aplicar por construcción. Ése sigue siendo el problema abierto, con sus dos obstáculos conocidos: el gradiente no fluye por la selección top- k , y el índice queda obsoleto a medida que el codificador se mueve.
2. **Corpus sintético.** Entidades, atributos y las cuatro formulaciones elípticas son sintéticos y fijos; no son una muestra de correcciones humanas.
3. **La hidratación se modela como todo o nada.** Un resolutor real puede fallar de peores maneras — hidratar con la entidad *equivocada* —, algo que no modelamos y que sería más dañino que no hidratar.

4. τ es un **parámetro impuesto, no medido**. El experimento entrega el punto de cruce; no dice en qué lugar de ese eje se encuentra un sistema de producción dado.
5. **Una sola familia de codificadores**. Todos los resultados usan `nomic-embed-text`; la patología de capitalización de la sección 3.4 recuerda que el comportamiento específico del codificador es un factor real.

9. Conclusión

Nos propusimos poner a prueba si la geometría de un índice de embeddings puede cargar con la relación entre versiones de un hecho recordado. A lo largo de tres experimentos pre-registrados la respuesta es que no, y cada vez por una razón identificable: con paso fijo el clúster se va caminando; acotado, paga un peaje constante; y en el régimen elíptico diseñado para favorecerlo, sólo gana cuando la alternativa ya está rota más allá de toda utilidad.

El negativo sale fortalecido, y no debilitado, por el tercer experimento: construimos la condición bajo la cual nuestra propia explicación debía fallar, y no falló. Lo que queda es un dictamen de diseño que coincide, por una vía independiente, con la posición de la frescura determinista — *geometría para agrupar, metadato para ordenar* — y una advertencia práctica con un número detrás: si un sistema de memoria almacena los turnos conversacionales tal como fueron escritos, toda corrección que no nombre a su sujeto ya está perdida, y nada en el sistema lo va a avisar.

Disponibilidad de datos y código

Todos los pre-registros, hashes, scripts de análisis, resultados crudos por semilla e informes generados directamente por el código de análisis están archivados en el repositorio del proyecto. Cada veredicto de este trabajo lo emite un script congelado antes de que existieran los datos correspondientes; ninguno se calculó a mano.

Declaraciones

Financiamiento. Ninguno.

Conflictos de interés. El autor declara no tener conflictos de interés.

Contribuciones. El autor es el único responsable del diseño, la implementación, el análisis y la redacción.

Referencias

- [1] Wu, D. et al. LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory. *International Conference on Learning Representations (ICLR)*, 2025.
- [2] Don't Ask the LLM to Track Freshness: A Deterministic Recipe for Memory Conflict Resolution. *arXiv preprint arXiv:2606.01435*, 2026.
- [3] REMem: hybrid memory graph with gists and timestamped facts. *International Conference on Learning Representations (ICLR)*, 2026.
- [4] NeuSymMS: self-curated neuro-symbolic memory for persistent agents. *arXiv preprint arXiv:2605.17596*, 2026.

- [5] Supersede: diagnosing and training the memory-update gap. *arXiv preprint arXiv:2606.27472*, 2026.
- [6] Kanerva, P. *Sparse Distributed Memory*. MIT Press, 1988.
- [7] Graves, A. et al. Hybrid computing using a neural network with dynamic external memory. *Nature* 538, 471–476, 2016.
- [8] Attention and sparse distributed memory: formal correspondence. *arXiv preprint arXiv:2303.11934*, 2023.
- [9] Basu et al. On the instability of coordinate systems learned jointly with the model. *arXiv preprint arXiv:2603.22858*, 2026.
- [10] Wu, Y. et al. Memorizing Transformers. *International Conference on Learning Representations (ICLR)*, 2022. arXiv:2203.08913.
- [11] Memory Layers at Scale. *arXiv preprint arXiv:2412.09764*, 2024.
- [12] Cui, W. HOLA: A Hippocampus for Linear Attention. *arXiv preprint arXiv:2607.02303*, 2026.
- [13] Lufkin, L. et al. Hybrid Associative Memories. *arXiv preprint arXiv:2603.22325*, 2026.
- [14] Query Drift Compensation. *arXiv preprint arXiv:2506.00037*, 2025.