

La consulta no puede ver la pregunta

El alcance de una convolución corta decide qué parte de una consulta condiciona la recuperación, y lo que queda afuera se vuelve una respuesta equivocada y confiada

Maximiliano Speranza
Investigador independiente, Buenos Aires, Argentina
[ORCID 0009-0005-0413-8554](https://orcid.org/0009-0005-0413-8554)
maximiliano.speranza@gmail.com

Septiembre de 2026

Resumen

Los modelos de atención lineal y de espacio de estados arman su consulta con una convolución causal corta. El tamaño de núcleo 4 es el valor por omisión de hecho, así que la consulta de una capa resulta ser función del token actual y de tres anteriores. Mostramos que ese alcance no es un detalle de suavizado local sino un límite duro sobre *qué parte de una pregunta puede condicionar la recuperación*, y que lo que cae afuera no se degrada de a poco. Desaparece exacto, y el modelo contesta con confianza a partir de la parte que todavía alcanza a ver.

Medimos el efecto en un modelo de lenguaje chico con un archivo persistente co-entrenado que se consulta entre secuencias. La sensibilidad de la recuperación a un token de la consulta, medida como el movimiento en variación total de la distribución de lectura cuando ese token se reemplaza, vale **0,000000** apenas el token pasa el alcance de la convolución, y el corte se mueve con el núcleo. Con núcleo 3 (alcance 2) el escalón cae entre las distancias 2 y 3, y con núcleo 5 (alcance 4) entre 4 y 5. Sesenta celdas de sesenta, dos arquitecturas, tres semillas cada una, dos componentes de la consulta y cinco distancias.

La consecuencia en el comportamiento es una falla específica y frecuente. En nuestra tarea las preguntas tienen la forma *cuál es la <relación> de <entidad>*, con la entidad a distancia 1 de la posición de lectura y la relación a distancia 3. Con núcleo 3 la relación queda afuera de la ventana en el 100 % de las consultas, así que el modelo recupera solamente por la entidad. Cuando se le pregunta por una relación que nunca se enunció, sobre una entidad que sí apareció, responde con el hecho archivado equivocado en vez de abstenerse, y la abstención correcta queda en 0,5850 a 0,7349 sobre tres semillas. Ensachar el núcleo a 5, que cuesta 1,280 parámetros sobre 865,395, la lleva a **0,9931** hasta **1,0000** sin solape entre condiciones, y la exactitud global a 0,988 hasta 0,993 contra un piso trivial de 0,4065.

Después verificamos el mecanismo afuera de nuestro propio modelo. En *mamba-130m-hf*, de 129 millones de parámetros, cambiar un token de cinco a ocho posiciones antes de la lectura mueve la salida de la capa en todas las distancias y deja la salida de la convolución en **cero exacto**, 80 celdas de 80. El estado ve la secuencia entera y la consulta que lo lee no. De paso, el tap más viejo de la convolución en ese checkpoint vale cero exacto en las 24 capas, así que su alcance efectivo es 2 y no el nominal 3. Informamos la medición y no una causa.

Damos el diagnóstico como una receta que no necesita entrenamiento. Se cambia un token de la consulta y se mira si la recuperación se mueve. Si no se mueve, ese token es invisible para la búsqueda, y la confianza que el modelo muestre sobre él no está ganada.

1. El problema

Un modelo con memoria persistente tiene que hacer dos cosas que suelen medirse juntas y en realidad son separadas. Tiene que *encontrar* la entrada correcta, y tiene que *saber* cuándo la

entrada que busca no está. La segunda es la que separa una memoria de un fabulador, y es la difícil de las dos.

Encontramos que en nuestro propio sistema la segunda falla tenía una causa puramente mecánica, aguas arriba de todo lo que el modelo aprende. La consulta con la que se busca en el archivo se arma con una convolución causal corta sobre los estados ocultos. En una pregunta de la forma *cuál es <art> <sust> de <entidad>*, la entidad queda un token antes de la posición de lectura y el sustantivo que nombra la relación queda tres tokens antes. Un núcleo de tamaño 3 alcanza dos tokens hacia atrás. La relación cae un token afuera de la ventana, de forma determinista, en todas y cada una de las consultas.

El modelo no estaba ignorando la relación. No la podía ver.

2. Trabajo relacionado

Las convoluciones cortas están en todos lados y su tamaño se hereda, no se mide. Mamba-2 (Dao y Gu, 2024) usa por omisión una convolución causal depthwise de tamaño 4. En la implementación de referencia de Qwen3-Next, que usa Gated DeltaNet (Yang et al., 2025) en sus capas de atención lineal, la configuración expone `linear_conv_kernel_dim`, documentado como el tamaño de núcleo de la convolución de las capas de atención lineal y **con valor por omisión 4** (Hugging Face, 2026). Las ablaciones de esta línea informan que sacar la convolución empeora el modelo, lo cual establece que el contexto local importa. Ninguna informa qué se pierde cuando la ventana está presente pero es demasiado angosta para la consulta que hay que armar. Un alcance de tres tokens no es una configuración exótica, es lo que corre en modelos desplegados.

El resultado teórico más cercano. Li et al. (2024) estudian el recuerdo asociativo de n -gramas y prueban, por construcción, que alcanza con un filtro causal de largo N , igualando el filtro al n -grama. Es la misma familia de idea y la citamos como precursora. Tres cosas la separan de lo que informamos acá. Su consulta es un n -grama *contiguo*, los últimos N tokens sin nada irrelevante en el medio, mientras que lo que manda en nuestro caso es la *distancia* de un componente, con relleno entre las dos partes que importan. Su Teorema 1 es un resultado de existencia y no corren ningún experimento con el filtro demasiado corto. Y en la práctica informan lo contrario, al decir que la convolución sobre consultas y claves ayuda en las construcciones teóricas pero no da beneficios apreciables en los experimentos reales. Nosotros medimos un efecto grande en un régimen que ellos no prueban, que es una memoria persistente *entre secuencias* con una consulta compuesta.

Por qué el campo no lo pudo ver. La tarea canónica para esta capacidad, MQAR (Arora et al., 2024), tiene una consulta de *un solo token*. Se busca la clave y se devuelve el valor. Por construcción esa consulta no puede tener una parte adentro de la ventana y otra afuera. Zoology atribuye el 82 % de la brecha de recuerdo a que la convolución aplica un filtro fijo e independiente de la entrada, que es una afirmación sobre *adaptabilidad*. La nuestra es sobre *alcance*, y las dos son independientes. Nuestro modelo de núcleo 5 tiene exactamente la misma independencia de la entrada y la falla desaparece.

Del lado de la atención. La atención multi-token (Golovneva et al., 2025) convoluciona sobre los pesos de atención para que la atención pueda condicionarse en varios tokens a la vez, motivada por la observación de que un solo token no alcanza para localizar una coincidencia. Va en la misma dirección y confirma la nuestra por contraste. Nunca se pregunta qué parte de la consulta queda ciega, y no conecta la pregunta con la abstención.

3. Montaje experimental

El sustrato es un modelo de lenguaje de 3,5 MB, 865,395 parámetros, $d = 128$, cuatro bloques, entrenado desde cero sobre un idioma sintético cerrado de 242 tokens con un archivo persistente

co-entrenado. Los hechos se enuncian en una secuencia, se revisan en otra y se consultan en una tercera, **con el estado recurrente reseteado entre secuencias**, así que la recuperación no se puede resolver arrastrando activaciones hacia adelante.

Las consultas se leen en el último token de la pregunta. La lectura se inyecta en el bloque 0 **antes del mixer**, y eso importa para el mecanismo. En ese punto el estado oculto todavía es la embedding del token, sin ninguna mezcla recurrente, así que la ventana de la convolución es literalmente todo lo que la consulta puede ver. Eso también explica por qué el efecto de abajo puede ser cero exacto y no apenas chico.

Se puntúan por separado cuatro categorías de respuesta. **vigente** y **anterior** son preguntas con respuesta en el archivo. **nose_ent** pregunta por una entidad que nunca se mencionó, que es la ausencia fácil. **nose_rel** pregunta por una relación que nunca se enunció *sobre una entidad que sí apareció*, que es el caso que se parece a una alucinación real, porque la recuperación encuentra un hecho vecino y genuino.

4. Resultado 1. La ventana es una función escalón, y afuera vale cero exacto

Medimos la sensibilidad reemplazando un componente de la pregunta por otro del mismo tipo y registrando la distancia en variación total entre las distribuciones de lectura. Para variar la distancia sin tocar la pregunta, la posición de lectura se corre r lugares sobre el relleno que ya sigue al signo de pregunta, que es exactamente equivalente a agregar r rellenos.

modelo	núcleo (alcance)	$d=1$	$d=2$	$d=3$	$d=4$	$d=5$	$d=6$
v3 (3 semillas)	3 (2)	0,71–0,74	0,15–0,25	0,000000	0,000000	0,000000	0,000000
kq3 (3 semillas)	5 (4)	0,36–0,46	0,10–0,15	0,05–0,35	0,07–0,33	0,000000	0,000000

Sesenta celdas de sesenta coinciden con la predicción hecha antes de correr, que la sensibilidad es positiva mientras $d \leq$ alcance y cero más allá. Una celda daba al principio 0,0106 donde iba un cero. La causa era que la formulación por el valor anterior es dos tokens más larga, así que correr la posición de lectura la recortaba contra el borde del tensor, y recortar *acorta* la distancia que se está midiendo. Esas muestras ahora se descartan en vez de recortarse y la celda pasó a 0,000000.

5. Resultado 2. Ensanchar la ventana compra abstención

unidad	núcleo	vigente	nose_ent	nose_rel	abstención falsa
kq3_s0	5	1,0000	0,9538	0,9931	0,0000
kq3_s1	5	0,9964	0,9726	1,0000	0,0030
kq3_s2	5	1,0000	0,9356	1,0000	0,0000
v3_s0	3	1,0000	0,9851	0,6090	0,0000
v3_s1	3	1,0000	1,0000	0,5850	0,0000
v3_s2	3	0,9927	0,9414	0,7349	0,0064

No hay solape entre condiciones en **nose_rel**. La exactitud global, contando una abstención correcta como acierto, va de 0,988 a 0,993 con núcleo 5 contra un piso trivial de 0,4065, que es lo que saca un modelo que se abstiene en todo.

El costo existe y lo declaramos. **nose_ent**, el caso fácil, baja un poco, de 0,941–1,000 a 0,936–0,973. Una lectura que informe solamente un número agregado de abstención esconde ese intercambio.

No es capacidad. El modelo de núcleo 5 agrega 1,280 parámetros, el 0,15 %, y el control de núcleo 3 ya recupera la entrada correcta con probabilidad 1,0000. Lo que cambia es el acceso, y el Resultado 1 lo mide directo.

6. Resultado 3. Apagar el tap que alcanza la relación

Apagar de a un tap por vez en el modelo de núcleo 5 ya entrenado, sin reentrenar nada, daña **vigente** en 0,483, 0,582 y 0,530 para el tap que alcanza la relación, contra 0,372, 0,013 y 0,195 para el tap que alcanza una palabra funcional y 0,218, 0,093 y 0,157 para el que alcanza el artículo. El tap de la relación tiene la magnitud aprendida *más chica* de los cinco, así que por unidad de peso cuesta cerca del doble que cualquiera de los dos controles.

Un criterio preregistrado formulado sobre la métrica de abstención falló, e informamos por qué. Apagar el tap saca la relación de *todas* las consultas, así que el modelo se abstiene más, y una métrica que premia abstenerse no puede bajar. El daño aparece en la exactitud y en la abstención falsa.

7. Resultado 4. La disociación se sostiene en un modelo real

Todo lo anterior está medido en un modelo chico, así que verificamos el mecanismo en uno que no es nuestro. `state-spaces/mamba-130m-hf`, 129,135,360 parámetros, en CPU y sin entrenar nada. En Mamba la convolución corta se aplica a x *antes* de calcular B , C y Δ , y C_t es el análogo de la consulta de lectura.

Cambiamos un solo token a distancia d de una posición de lectura y medimos, en la capa 0, el movimiento de la salida de la convolución y el de la salida de la capa. Diez posiciones de lectura, dos textos.

	$d=1$	$d=2$	$d=3$	$d=5$	$d=7$	$d=8$
salida de conv1d	0,8–3,7	0,5–1,6	0,0	0,0	0,0	0,0
salida de la capa	9×10^{-2}	2×10^{-2}	2×10^{-2}	1×10^{-2}	9×10^{-2}	1×10^{-2}

La salida de la capa se mueve en *todas* las distancias, 80 celdas de 80, así que el estado sí ve la secuencia entera. La salida de la convolución vale cero exacto más allá de su alcance. **Eso es la disociación.** El modelo ve el contexto y la consulta que lee su estado no lo ve.

Un hallazgo incidental, informado con su incertidumbre. Habíamos predicho movimiento en $d = 3$, porque el núcleo es 4. Vale cero exacto. La razón es que **el tap más viejo de la convolución vale cero exacto en las 24 capas**, lo que confirmamos por los pesos y también por intervención, ya que cambiar un token mueve la salida de la convolución en exactamente tres posiciones consecutivas y no cuatro. La ventana efectiva de este checkpoint es 3 y no 4, y el alcance es 2. No sabemos la causa. Un peso que vale cero exacto en 24×1536 entradas no sale de un gradiente, así que un artefacto de conversión es plausible, pero no lo verificamos y no lo afirmamos. El hecho se reproduce en tres líneas. Su consecuencia práctica, si generaliza, es que el núcleo nominal es una cota superior del alcance y conviene medirlo en vez de suponerlo.

8. Resultado 5. En un modelo profundo la ventana atenúa en vez de bloquear, y la tasa es la misma en dos tamaños

El Resultado 4 midió el acceso en la capa 0 de un modelo real. La objeción obvia es que un modelo recurrente profundo tiene muchas capas para mover la información hacia adelante, así que un cero duro en una capa no tiene por qué importar. Lo medimos de frente, y la respuesta es más útil que cualquiera de los dos extremos.

Qué se mide, y por qué acá la distancia es entre las dos partes. En nuestro modelo chico la consulta se forma en el último token y lee un archivo externo, así que la distancia que decide es la de cada componente a la posición de lectura. Un modelo de lenguaje recurrente no tiene archivo externo: la memoria es el estado, se actualiza en *cada* posición, y cada token tiene su propio turno de condicionar la búsqueda cuando entra. Para responder hay que *combinar* la entidad y la relación, y esa combinación puede ocurrir en cualquier posición donde las dos estén disponibles. La distancia que decide es entonces la que separa la relación de la entidad, y medimos el movimiento de la salida de `conv1d` en la posición de la entidad al reemplazar el token de la relación.

Montaje. Quince formas de pregunta que abarcan seis distancias relación–entidad, ocho contextos al azar de cuatro hechos cada uno, todas las capas, en `state-spaces/mamba-130m-hf` (24 capas) y `state-spaces/mamba-370m-hf` (48 capas). El alcance medido de la convolución es 2 en los dos. La atenuación se informa contra el promedio de las formas con $d=2$.

	$d=2$	$d=3$	$d=4$	$d=5$	$d=6$	$d=7$
capa 0 (los dos modelos)	se mueve	0,0	0,0	0,0	0,0	0,0
atenuación en la capa 1, 130m	1,10	2,31	3,06	4,64	4,65	6,92
atenuación en la capa 1, 370m	1,04	3,21	3,17	4,47	5,72	6,47

- **En la capa 0 el corte es exacto y cae en el alcance medido**, en los dos modelos: $d=2$ se mueve y $d \geq 3$ vale cero exacto. Es el Resultado 1 reproducido en un modelo que no es nuestro y a otra profundidad.
- **Desde la capa 1 ya no es cero.** La recurrencia sí transporta la relación hacia adelante. Pero la señal llega atenuada, y la atenuación crece con la distancia: el ajuste lineal da 1,077 por token ($r = 0,9784$) en 130m y 1,028 por token ($r = 0,9777$) en 370m. Las dos curvas correlacionan a 0,9549.
- **Tres veces los parámetros y el doble de capas no cambian la tasa.** Eso hace de la atenuación una propiedad de la arquitectura y no de un checkpoint particular.

El control que adjudica, y uno que no. Si la atenuación dependiera de qué palabras hay en el medio en vez de cuántas, el efecto sería léxico y no arquitectónico. Por eso dejamos fija la distancia y variamos el relleno: con $d=5$, cuatro rellenos distintos (*of the person named, of that other person, in the file for, of our dear friend*) se dispersan por un factor de 1,98, contra un rango de 1,10 a 6,92 entre distancias. La distancia decide; el relleno no.

Informamos también un control que falló, por una razón instructiva. Primero probamos dejar $d=2$ y alargar la pregunta *después* de la entidad. Devolvió valores idénticos a la condición base hasta el último decimal en las 24 capas, y tenía que hacerlo: nada que venga después de una posición puede afectar a esa posición. Era causalidad disfrazada de control, y vale la pena dejar escrita la prueba que caza esta clase de error antes de que lleguen los datos — *si la hipótesis fuera falsa, ¿este control podría dar distinto?*

Un titular que descartamos. Leer la capa en la que la atenuación baja por primera vez de 1,5 da 0,9, 9, 13, 19, 21 para $d = 2 \dots 7$, o sea unas cuatro capas por token de distancia, con $r = 0,971$. Al barrer el umbral de 1,2 a 2,5 esa pendiente va de 3,97 a 1,54 y el orden se rompe, así que la cantidad es un artefacto del umbral y no se informa. La atenuación en la capa 1 no depende de ningún umbral, y es lo que dice el párrafo de arriba.

Qué cambia esto sobre la afirmación. La forma fuerte de la ley — cero exacto fuera del alcance — vale *por capa*, y vale en la capa donde se inyecta una lectura. En un modelo profundo se convierte en una ley de atenuación: la ventana no decide qué puede llegar a combinar el modelo, decide cuánto cuesta esa combinación. Ésta es la versión cuantitativa de la limitación que en el primer borrador declaramos sin medir, y precisa dónde se aplica la afirmación fuerte: a la memoria consultada desde una capa temprana, donde no quedan capas con que pagar.

9. El diagnóstico, como receta

La medición del Resultado 1 no necesita entrenamiento ni gradientes. Para cualquier modelo que consulte una memoria con una consulta armada desde una ventana local.

1. Tomar una consulta con sus partes separadas, de modo que algún componente quede a distancia d de la posición de lectura.
2. Reemplazar ese componente por otro del mismo tipo.
3. Comparar las distribuciones de recuperación.

Si son idénticas, ese componente es invisible para la búsqueda, y la confianza que el modelo muestre sobre él no está ganada. Con un núcleo de 4, que es el valor por omisión en las capas de atención lineal desplegadas, el alcance es de tres tokens, así que cualquier parte de una pregunta que quede más atrás no entra en la consulta de esa capa.

10. Limitaciones

El sustrato es un modelo chico sobre un idioma sintético cerrado, y la distancia entre la relación y la posición de lectura la fija el generador, así que el efecto acá es determinista donde en texto natural sería una distribución. La medición es de *acceso* y no de uso. Un token adentro de la ventana no necesariamente se usa, y de hecho el tap del artículo está adentro y aporta poco. Por último, la lectura en nuestro modelo se inyecta antes del mixer, que es lo que hace que el cero sea exacto, y por eso la afirmación fuerte se hace para memoria consultada desde capas tempranas. El Resultado 5 mide qué pasa cuando no es así: la recurrencia transporta, pero la señal llega atenuada a razón de un factor $\approx 1,05$ por token de distancia, replicado en dos profundidades. Lo que esa medición *no* dice es si la señal atenuada alcanza para la tarea. Es una medición de magnitud, no de utilidad, y en las capas altas la atenuación tiende a 1 sin que sepamos si eso significa que la información se recuperó o que la representación pasó a estar dominada por otra cosa.

Referencias

- Dao, T., y Gu, A. (2024). Transformers are SSMs. Generalized Models and Efficient Algorithms Through Structured State Space Duality. ICML 2024.
- Yang, S., Kautz, J., y Hatamizadeh, A. (2025). Gated Delta Networks. Improving Mamba2 with Delta Rule. ICLR 2025. arXiv:2412.06464.
- Documentación de Hugging Face Transformers, `Qwen3NextConfig`, parámetro `linear_conv_kernel_dim`, valor por omisión 4. Consultada el 2 de septiembre de 2026.
- Li, M., Zhang, X., Huang, Y., y Oymak, S. (2024). On the Power of Convolution Augmented Transformer. arXiv:2407.05591.

Arora, S., Eyuboglu, S., Timalsina, A., Johnson, I., Poli, M., Zou, J., Rudra, A., y Ré, C. (2024). Zoology. Measuring and Improving Recall in Efficient Language Models. ICLR 2024. arXiv:2312.04927.

Golovneva, O., Wang, T., Weston, J., y Sukhbaatar, S. (2025). Multi-Token Attention. arXiv:2504.00927.