

El vocabulario del micro-LM

Las 242 palabras que el modelo conoce, y ninguna mas.

Son 242 palabras, no 128. El 128 que aparece en la configuracion es otra cosa, es el ancho interno del modelo, o sea cuantos numeros usa para representar cada palabra. Se llama *d* y no tiene relacion con el tamaño del vocabulario.

El idioma es **cerrado**. El modelo nunca ve una palabra fuera de esta lista, ni en el entrenamiento ni en las pruebas. Eso es a proposito, porque asi cualquier error que cometa es un error de razonamiento o de memoria, y nunca de no entender una palabra nueva.

GRUPO	PALABRAS	DEL TOTAL
Marcas de control	6	2.5 %
Numeros	100	41.3 %
Nombres de persona	58	24.0 %
Entidades	29	12.0 %
Relaciones	11	4.5 %
Palabras de union	35	14.5 %
Puntuacion	3	1.2 %
TOTAL	242	100 %

Marcas de control6

No son palabras que alguien diga. Ordenan la conversacion y marcan quien habla. **NOSE** es la mas importante del proyecto, porque es literalmente la palabra con la que el modelo dice que no sabe.

- BOSSEPSEOSUSUARIOMODELONOSE

Numeros100

Del 0 al 99. Son los valores de las relaciones que no son de persona, como un precio o una altura.

- 012345678910111213141516171819202122

2324252627282930313233343536373839404142

4344454647484950515253545556575859606162

6364656667686970717273747576777879808182

8384858687888990919293949596979899

Nombres de persona

58

Los valores posibles cuando la pregunta es por alguien, por ejemplo quien dirige un lugar.

ana beto carla dario elsa fabio gema hugo irma julio kena luis mara nico
olga pablo quena raul sofia tomas ursula vera walter ximena yago zoe abril
bruno celia diego emma franco gala ivan julia kevin lara marco nadia oscar
paula ramiro sara teo vale wanda yamil zaira agus bruna ciro dana enzo
flor gonza hilda ian jazmin

Entidades

29

Las cosas y lugares sobre los que se habla. Cada hecho del archivo trata sobre una de estas.

norte sur este oeste centro taller tienda equipo club museo teatro puerto
granja banco hotel bosque puente barrio plaza mercado escuela fabrica estudio
parque templo faro molino laguna cabaña

Relaciones

11

Lo que se puede preguntar de una entidad. Cada una aparece como sustantivo y como verbo, porque el modelo tiene que reconocer el mismo hecho dicho de varias formas. Dato curioso, **vale** esta contada arriba entre los nombres de persona y ademas es el verbo de la relacion *clave*, como en «la clave vale 42». Es la unica palabra del idioma con dos papeles, y el modelo tiene que desambiguarla por contexto.

altura clave cuesta cuida director dirige dueño guardia mide posee precio

Palabras de union

35

Articulos, preposiciones y marcadores de tiempo. Son el pegamento que arma las frases.

el la de del es era esta en un una y o no si ahora antes ayer hoy
cual quien que a tiene como con por para se lo su mas menos tambien
pero entonces

Puntuacion

3

Nada mas que esto.

? , .

Una conversacion se parte en sesiones y la memoria del modelo se borra entre una y otra. Tiene que acordarse igual, y quedarse con la version mas nueva de cada dato.

sesion 1	USUARIO	el director de norte es ana
sesion 2	USUARIO	no , el director de norte es beto
sesion 5	USUARIO	quien dirige norte ?
	MODELO	beto
sesion 6	USUARIO	quien cuida el museo ?
	MODELO	NOSE (nadie lo dijo nunca)

Extraido de **micro_lm/idioma.py** el 28 de agosto de 2026. Modelo de 863.730 parametros. La respuesta del modelo es siempre **una sola palabra**, un valor o NOSE, para que corregirlo no dependa de interpretar un texto largo.